

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC



BÁO CÁO
ĐỀ TÀI: TỐI ƯU HÓA DANH MỤC ĐẦU TƯ VỚI
COPULA

KHÓA LUẬN TỐT NGHIỆP
Năm học: 2025 - 2026

GIẢNG VIÊN HƯỚNG DẪN

ThS. Nguyễn Hữu Toàn

SINH VIÊN THỰC HIỆN

Phan Hoàng Đạt - 22110037.

Hồ Chí Minh – 2026

Lời cam đoan

Tôi xin cam đoan rằng, báo cáo này là sản phẩm được thực hiện bởi tôi, được thực hiện dựa trên sự hướng dẫn của giáo viên hướng dẫn và các tài liệu tham khảo được trích dẫn đầy đủ. Mọi dữ liệu, số liệu và kết quả trình bày trong luận văn đều trung thực và chưa từng được sử dụng trong bất kỳ công trình nào trước đây, trừ khi được chỉ rõ trong phần tham khảo.

Tôi xin chịu trách nhiệm hoàn toàn về tính trung thực và chính xác của nội dung bài báo cáo.

Lời cảm ơn

Quá trình học môn học này là một giai đoạn rất quan trọng. Nó là tiền đề nhằm trang bị cho em những kỹ năng nghiên cứu, những kiến thức quý báu, tạo bước đệm cho quá trình sau này.

Trước hết, em xin chân thành cảm ơn ban lãnh đạo khoa đã tạo điều kiện học tập tốt nhất với môi trường học tập hiện đại, trang thiết bị đầy đủ, giúp em tiếp cận với các công nghệ và phương pháp thực hành tiên tiến.

Đặc biệt em xin chân thành cảm ơn giáo viên hướng dẫn của chúng tôi, Ths. Nguyễn Hữu Toàn, vì sự hỗ trợ và hướng dẫn tận tình trong suốt môn học cũng như là quá trình thực hiện báo cáo. Em cũng muốn bày tỏ lòng biết ơn đến gia đình và bạn bè, những người đã luôn ủng hộ và khích lệ chúng tôi trong mọi hoàn cảnh.

Mặc dù đã cố gắng hết mình, nhưng bài báo cáo chắc chắn không tránh khỏi những thiếu sót. Rất mong nhận được những ý kiến đóng góp từ thầy để bài báo cáo được hoàn thiện hơn.

Mục lục

I	MỞ ĐẦU (INTRODUCTION)	5
I.1	Bối cảnh nghiên cứu	5
I.2	Mục tiêu nghiên cứu	5
I.3	Phạm vi và giới hạn nghiên cứu	5
II	CƠ SỞ LÝ THUYẾT	6
II.1	Bài toán tối ưu hóa Mean-VaRiance (Markowitz)	6
II.1.1	Quy tắc trung bình-phương sai và đa dạng hóa	6
II.1.2	Danh mục đầu tư rủi ro tối thiểu (MVP)	7
II.1.3	Danh mục đầu tư có tài sản phi rủi ro	7
II.2	Copula và sự phụ thuộc đuôi	8
II.2.1	Các Copula	8
II.2.2	Các ví dụ của Copula	10
II.2.3	Phân phối meta	11
II.2.4	Các đặc tính khác của Copula	12
II.2.5	Sự phụ thuộc hoàn hảo	13
II.3	Các thước đo sự phụ thuộc đuôi	13
II.3.1	Tương quan tuyến tính	13
II.3.2	Tương quan hạng	14
II.3.3	Các hệ số phụ thuộc đuôi	15
II.4	Các Copula hỗn hợp chuẩn	16
II.4.1	Phụ thuộc đuôi	16
II.4.2	Tương quan hạng	17
II.5	Các Copula Archimedean	18
II.6	Hiện tượng đuôi nặng	19
III	Ứng dụng mô phỏng Monte Carlo từ Copula	20
III.1	Quy trình chung cho phân phối Meta	21
III.2	Mô phỏng Gauss Copula	21
III.3	Mô phỏng t Copula	21
III.4	Mô phỏng Copula Archimedean (LT-Archimedean)	22
III.5	Các thuật toán nâng cao cho phân phối hỗn hợp chuẩn	22
IV	CÁC TIÊU CHÍ KIỂM ĐỊNH VÀ PHƯƠNG PHÁP NGHIÊN CỨU	22
IV.1	Thu thập và xử lý dữ liệu	22
IV.2	Thống kê mô tả và Kiểm định dữ liệu đầu vào	23
IV.2.1	Hệ số bất đối xứng và hệ số nhọn	23
IV.2.2	Kiểm định tính chuẩn Jarque-Bera (JB)	24
IV.3	Phương pháp ước lượng và kiểm định hàm Copula	24
IV.3.1	Phương pháp ước lượng hàm Copula	24
IV.3.2	Kiểm định độ phù hợp Cramér-von Mises (sử dụng chỉ số MSE)	25
IV.4	Quy trình mô phỏng Monte Carlo và tối ưu hóa danh mục đầu tư	25
IV.5	Quy trình phân tích dữ liệu	26

V PHÂN TÍCH MÔ PHỎNG VÀ KẾT QUẢ	26
V.1 Phân tích đơn biến	26
V.2 Phân tích biến phụ thuộc	27
V.3 Tối ưu hóa danh mục đầu tư	28
V.4 Áp dụng mô hình Copula	30
V.5 Mô hình mô phỏng Monte Carlo và tối ưu hóa rủi ro	31
V.5.1 Phân tích mô phỏng Monte Carlo với 10.000 kịch bản	31
V.5.2 Chiến lược tối ưu hóa danh mục theo rủi ro đuôi (CVaR)	32
V.6 Dự báo hiệu suất danh mục tối ưu trong dài hạn (1 năm)	32
VI Ý NGHĨA PHƯƠNG PHÁP QUẢN TRỊ	34
VI.1 Giải thích kết quả	34
VI.2 Ý nghĩa cho doanh nghiệp	34
VI.3 Ý nghĩa cho nghiên cứu học thuật	34
VII KẾT LUẬN VÀ HƯỚNG NGHIÊN CỨU TƯƠNG LAI	35
VII.1 Tóm tắt kết quả chính	35
VII.2 Hướng nghiên cứu trong tương lai	35
Tài liệu tham khảo	36
Phụ lục A	37

I MỞ ĐẦU (INTRODUCTION)

I.1 Bối cảnh nghiên cứu

Trong quản trị rủi ro tài chính, hệ số tương quan tuyến tính truyền thống thường không thể đo lường chính xác các biến động rủi ro, đặc biệt là khi thị trường rơi vào giai đoạn khủng hoảng. Bản chất của hệ số tương quan tuyến tính chỉ là đo lường mức độ liên kết tuyến tính trung bình giữa hai biến số. Tuy nhiên, trên thực tế, khi thị trường xảy ra khủng hoảng, các tài sản tài chính lại có xu hướng sụp đổ cùng nhau một cách mạnh mẽ hơn nhiều so với điều kiện bình thường; thậm chí tồn tại trường hợp hai biến có tương quan tuyến tính cao nhưng lại hoàn toàn không có sự phụ thuộc đuôi. Chính vì vậy, việc chỉ dựa vào tương quan tuyến tính hoặc áp đặt giả định độc lập có thể dẫn đến việc đánh giá thấp một cách nghiêm trọng xác suất xảy ra các tổn thất lớn.

Để giải quyết hạn chế này, lý thuyết Copula đã được xem như một công cụ mạnh mẽ thay thế cho hệ số tương quan tuyến tính nhờ vào khả năng tách biệt các hàm phân phối biên ra khỏi cấu trúc phụ thuộc. Tóm lại, hệ số tương quan tuyến tính thất bại vì nó giả định một mối quan hệ đồng nhất trên toàn bộ phân phối, trong khi rủi ro thực sự trong các cuộc khủng hoảng lại nằm ở sự hội tụ của các giá trị cực hạn tại đuôi phân phối, một đặc tính mà chỉ mô hình Copula mới có thể nắm bắt và phản ánh một cách hiệu quả [4].

I.2 Mục tiêu nghiên cứu

Nghiên cứu này hướng đến mục tiêu ứng dụng lý thuyết Copula để mô hình hóa cấu trúc sự phụ thuộc đuôi, tức là hiện tượng các tài sản tài chính sụt giảm giá trị đồng thời. Trên cơ sở đó, nghiên cứu tiến hành xây dựng một danh mục đầu tư tối ưu có tính bền vững cao hơn nhằm khắc phục những nhược điểm và mang lại hiệu quả vượt trội hơn so với mô hình Markowitz truyền thống.

I.3 Phạm vi và giới hạn nghiên cứu

Về phạm vi nghiên cứu và ứng dụng: Đề tài tập trung ứng dụng mô hình Copula như một công cụ cốt lõi trong quản trị rủi ro danh mục đầu tư. Phương pháp này cho phép tách biệt phân phối biên của từng cổ phiếu khỏi cấu trúc phụ thuộc chung (mô hình hóa từ dưới lên). Nhờ tính linh hoạt trên thang đo phân vị và dễ dàng kết hợp với mô phỏng Monte Carlo, nghiên cứu có thể giải quyết các bài toán định lượng rủi ro đuôi (Value at Risk - VaR) và dự báo các sự kiện cực đoan đa biến khi thị trường chứng khoán xảy ra khủng hoảng đồng loạt.

Về giới hạn của nghiên cứu: Việc ứng dụng mô hình này cũng đối mặt với một số thách thức nhất định. Rủi ro lớn nhất đến từ việc lựa chọn sai cấu trúc Copula (rủi ro mô hình), có thể dẫn đến đánh giá thấp các thảm họa mang tính hệ thống. Bên cạnh đó, mô hình Copula truyền thống được sử dụng trong bài thường mang tính tĩnh, thiếu linh hoạt khi mở rộng trong không gian đa chiều, và đặc biệt khó hiệu chuẩn chính xác do sự khan hiếm của các điểm dữ liệu lịch sử về những đợt tổn thất cực đoan đồng thời trên thị trường.

II CƠ SỞ LÝ THUYẾT

II.1 Bài toán tối ưu hóa Mean-VaRiance (Markowitz)

II.1.1 Quy tắc trung bình-phương sai và đa dạng hóa

Mô hình dựa trên giả thuyết rằng các nhà đầu tư coi tỷ suất lợi nhuận kỳ vọng là điều mong muốn và lo ngại rủi ro. Quá trình lựa chọn danh mục đầu tư gồm hai bước: đầu tiên là xác định các danh mục đầu tư tối ưu nằm trên đường biên hiệu quả dựa trên sự cân bằng giữa rủi ro và lợi nhuận, sau đó chọn danh mục phù hợp nhất với hàm thỏa dụng của từng nhà đầu tư tùy thuộc vào mức độ chấp nhận rủi ro và vốn đầu tư [1]. Markowitz đã thiết lập nền tảng cho việc lựa chọn danh mục đầu tư bằng cách ánh xạ mong muốn đầu tư lên biểu đồ rủi ro - lợi nhuận. Trong biểu đồ này thì lợi nhuận được đo bằng giá trị trung bình và rủi ro được đo bằng phương sai hoặc độ lệch chuẩn của phân phối lợi nhuận [5]. Công thức tính phương sai danh mục được xác định cụ thể như sau:

$$\sigma_w^2 = \text{Var}(R_w) = \sum_{i=1}^N \sum_{j=1}^N w_i w_j \sigma_i \sigma_j \rho_{ij} \quad (1)$$

Trong đó, ρ_{ij} là hệ số tương quan tuyến tính giữa các tài sản. Công thức này cho thấy rủi ro danh mục không phụ thuộc vào biến thiên riêng lẻ của từng tài sản mà phụ thuộc vào mối tương quan giữa các tài sản đó. Tuy nhiên, ρ chỉ đo lường mối quan hệ tuyến tính, và đây chính là điểm yếu mà hàm Copula sẽ khắc phục bằng cách tách biệt hàm phân phối biên và mô phỏng cấu trúc phụ thuộc phi tuyến.

Khi xem xét hai trường hợp biên với giả sử một danh mục gồm N tài sản có trọng số bằng nhau $w_i = \frac{1}{N}$, ta có các kết quả cụ thể. Trong trường hợp thứ nhất khi các tài sản không tương quan và độc lập với nhau, tức là $\rho_{ij} = 0$ với mọi $i \neq j$, phương sai danh mục được tính bằng:

$$\text{Var}(R_w) = \sum_{i=1}^N \left(\frac{1}{N} \right)^2 \sigma_i^2 = \frac{1}{N^2} \sum_{i=1}^N \sigma_i^2 \quad (2)$$

Khi $N \rightarrow \infty$ thì $\text{Var}(R_w) \rightarrow 0$. Việc có nhiều tài sản độc lập dẫn đến rủi ro danh mục càng nhỏ, điều này cho thấy rủi ro phi hệ thống có thể được triệt tiêu hoàn toàn nếu các tài sản không có sự liên kết với nhau. Trong trường hợp thứ hai khi các tài sản có tương quan với nhau, tức là $\rho_{ij} = c > 0$ với mọi $i \neq j$, hiệp phương sai giữa mọi cặp tài sản là $\sigma_{ij} = \text{Cov}(R_i, R_j) = c\sigma^2$. Khi đó, phương sai danh mục trở thành:

$$\begin{aligned} \text{Var}(R_w) &= \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N \sigma_{ij} = \frac{1}{N^2} \left(\sum_{1 \leq i \leq N} \sigma_{ii} + \sum_{1 \leq i < j \leq N} \sigma_{ij} \right) \\ &= \frac{\sigma^2}{N} + \left(1 - \frac{1}{N} \right) c\sigma^2 = \frac{1-c}{N} \sigma^2 + c\sigma^2 \end{aligned} \quad (3)$$

Khi $N \rightarrow \infty$, phương sai danh mục sẽ hội tụ về giới hạn:

$$\lim_{N \rightarrow \infty} \text{Var}(R_w) = c\sigma^2$$

Như vậy, dù có tăng số lượng tài sản đến vô hạn thì phương sai danh mục vẫn không thể nhỏ hơn $c\sigma^2$. Nếu $c = 0$ đối với tài sản độc lập, kết quả sẽ trở về trường hợp thứ nhất với

rủi ro giảm dần về 0 khi N tăng. Ngược lại, khi $c > 0$, rủi ro hệ thống chung giữa các tài sản luôn tồn tại và không thể loại bỏ được bằng đa dạng hóa.

Hạn chế của mô hình Markowitz là rủi ro này phụ thuộc chặt chẽ vào hệ số c tương quan tuyến tính. Tuy nhiên, trên thực tế, hệ số c thường tăng mạnh trong các giai đoạn thị trường hoảng loạn tạo nên hiện tượng tương quan đuôi. Nếu chỉ sử dụng mô hình trung bình - phương sai, nhà đầu tư sẽ đánh giá thấp rủi ro hệ thống này vì giả định c là một hằng số tuyến tính không đổi [5].

II.1.2 Danh mục đầu tư rủi ro tối thiểu (MVP)

Mục tiêu cốt lõi của danh mục đầu tư rủi ro tối thiểu (MVP) là tìm kiếm một tập hợp các tỷ trọng tài sản w sao cho tổng thể của danh mục được đo bằng phương sai σ_w^2 là nhỏ nhất, do nhà đầu tư coi rủi ro là điều không mong muốn và lợi nhuận kỳ vọng là điều mong muốn. MVP đại diện cho điểm mà tại đó sự lo ngại rủi ro được đẩy lên mức cao nhất và không quan tâm đến lợi nhuận đạt được bao nhiêu. Để xác định bài toán tối ưu toán học cho danh mục gồm N tài sản rủi ro được xác định bởi vectơ $W = (w_1, w_2, \dots, w_n)$, ta sử dụng ma trận hiệp phương sai $C = [\sigma_{ij}]$ với $\sigma_{ij} = \text{Cov}(R_i, R_j)$ và vectơ suất lợi nhuận $\mu = (\mu_1, \mu_2, \dots, \mu_n)$. Nhà đầu tư giải bài toán tối ưu hóa bằng phương pháp nhân tử Lagrange với hàm mục tiêu là giảm thiểu phương sai danh mục $\min \sigma_w^2 = w^T C w$ (trong đó w^T là ma trận chuyển vị của w), đi kèm ràng buộc tổng tỷ trọng các tài sản phải bằng 1, nghĩa là $\sum_{i=1}^N w_i = 1$ nhằm đảm bảo toàn bộ tài sản được đầu tư hết.

Ý nghĩa của hiệp phương sai được thể hiện qua công thức:

$$\sigma_w^2 = \sum_{i=1} w_i^2 \sigma_i^2 + 2 \sum_{i < j} w_i w_j \sigma_{ij} \quad (4)$$

Công thức này được tính dựa trên trọng số và các phần tử trong ma trận hiệp phương sai. Vai trò của hiệp phương sai giữa các tài sản là rất lớn, nếu hiệp phương sai âm hoặc thấp thì rủi ro tổng thể của danh mục sẽ giảm đáng kể nhờ các biến động ngược chiều triệt tiêu lẫn nhau [4]. Khi chuyển sang mô hình Copula, mối liên hệ này sẽ cho thấy rủi ro thực tế không chỉ nằm ở hiệp phương sai mà còn ở cấu trúc phụ thuộc phi tuyến tại các điểm cực trị của đuôi phân phối [5].

Đường biên hiệu quả của mô hình mang lại những kết quả quan trọng về mặt hình học và ứng dụng. Trên mặt phẳng rủi ro - lợi nhuận với trục hoành là độ lệch chuẩn σ và trục tung là lợi nhuận kỳ vọng μ , các danh mục khả thi tạo thành một vùng được bao bọc bởi một đường cong hình hyperbol. Điểm MVP của danh mục này nằm chính xác tại đỉnh của đường cong hyperbol, vốn là điểm cực trái nhất trên đồ thị. MVP cũng chính là điểm khởi đầu của đường biên hiệu quả; mọi danh mục nằm phía trên điểm MVP trên đường cong này được coi là hiệu quả, trong khi các danh mục nằm phía dưới MVP là không hiệu quả vì có rủi ro cao hơn nhưng lợi nhuận lại thấp hơn [1]. Sự ra đời của đường biên hiệu quả đã thúc đẩy sự phát triển bùng nổ của các phương pháp quản trị rủi ro trong thập kỷ tiếp theo, bao gồm các mô hình quan trọng như tỷ lệ Sharpe, mô hình định giá vốn tài sản (CAPM) và lý thuyết kinh doanh chênh lệch giá (APT).

II.1.3 Danh mục đầu tư có tài sản phi rủi ro

Lãi suất phi rủi ro r_f là tỷ suất sinh lời của một tài sản được coi là không có rủi ro vỡ nợ, thường là trái phiếu chính phủ ngắn hạn. Trong các mô hình định giá, lãi suất này được dùng làm lợi nhuận cơ sở để tính toán phần bù rủi ro [5]. Khi kết hợp tài sản phi rủi ro

với một danh mục tài sản rủi ro, tập hợp các danh mục đầu tư khả thi sẽ tạo thành một đường thẳng nối từ điểm phi rủi ro và đi qua điểm danh mục tài sản rủi ro đó. Đường biên hiệu quả mới lúc này không còn là hình hyperbol mà trở thành một đường thẳng tiếp tuyến với đường biên hiệu quả của các tài sản rủi ro. Đường này được gọi là đường thị trường vốn (Capital Market Line - CML).

Tỷ số Sharpe: Tỷ số Sharpe (Sharpe Ratio - SR_w) là một đại lượng cơ bản trong lý thuyết danh mục đầu tư hiện đại, đo lường tỷ lệ giữa phần thưởng trên sự biến động (reward-to-variability ratio). Định nghĩa một cách chuẩn xác, tỷ số Sharpe thể hiện mức lợi nhuận vượt trội kỳ vọng (phần bù rủi ro) mà nhà đầu tư nhận được trên mỗi đơn vị rủi ro tổng thể mà họ chấp nhận gánh chịu. Công thức toán học của tỷ số Sharpe đối với danh mục đầu tư w được xác định bởi:

$$SR_w = \frac{\mathbb{E}(R_w) - r_f}{\sigma_w} \quad (5)$$

Trong đó:

- $\mathbb{E}(R_w)$ là tỷ suất sinh lời kỳ vọng của danh mục đầu tư w .
- r_f là tỷ suất sinh lời của tài sản phi rủi ro.
- σ_w (hoặc $\text{std}(R_w)$) là độ lệch chuẩn của tỷ suất sinh lời danh mục, đại diện cho độ biến động hoặc rủi ro tổng thể.

Trong phân tích trung bình - phương sai, tỷ số Sharpe là thước đo chuẩn hóa để đánh giá hiệu suất: giá trị SR_w càng lớn biểu thị hiệu quả cấu trúc danh mục càng cao. Về mặt hình học, danh mục thị trường là danh mục tài sản rủi ro duy nhất tối đa hóa tỷ số Sharpe. Đây chính là tiếp điểm nơi đường thị trường vốn (Capital Market Line - CML) tiếp xúc với đường biên hiệu quả (efficient frontier).

Do đó, mọi danh mục đầu tư hiệu quả nằm trên đường CML đều sở hữu tỷ số Sharpe đồng nhất và bằng với tỷ số Sharpe của thị trường (SR_M), đồng thời SR_M đóng vai trò là giới hạn trên lý thuyết trong thế giới trung bình - phương sai. Dựa vào mối liên hệ này, chiến lược phân bổ tài sản tối ưu của nhà đầu tư là kết hợp phân bổ vốn giữa tài sản phi rủi ro và danh mục thị trường nhằm đạt được tỷ lệ lợi nhuận thặng dư trên rủi ro cao nhất.

II.2 Copula và sự phụ thuộc đuôi

Nội dung trong phần này được tổng hợp và phát triển chủ yếu dựa trên lý thuyết và các thuật toán nền tảng từ nguồn tài liệu [5]

II.2.1 Các Copula

Copula giúp hiểu về sự phụ thuộc ở mức độ sâu hơn, cho phép chúng ta thấy những cam ẩn tiềm ẩn của các phương pháp tiếp cận sự phụ thuộc vốn chỉ tập trung vào tương quan, đồng thời chỉ cho chúng ta cách xác định một số thước đo hữu ích. Copula tạo điều kiện cho phương pháp tiếp cận mô hình đi từ dưới lên. Cách tiếp cận Copula cho phép chúng ta kết hợp các mô hình biên đã phát triển kỹ lưỡng với nhiều mô hình phụ thuộc khả thi khác nhau, từ đó nghiên cứu mức độ nhạy cảm của rủi ro đối với các đặc điểm phụ thuộc được chỉ định. Vì các loại Copula rất dễ mô phỏng nên chúng đặc biệt phù hợp cho các nghiên cứu rủi ro bằng phương pháp Monte Carlo.

Các thuộc tính cơ bản: Một Copula d -chiều là một hàm phân phối trên khối lập phương đơn vị $[0, 1]^d$ với các phân phối biên đều tiêu chuẩn. Gọi C là một ánh xạ có dạng $C : [0, 1]^d \rightarrow [0, 1]$. Để C là một Copula thì nó phải thỏa mãn ba điều kiện: đầu tiên là $C(u_1, \dots, u_d)$ tăng trong mỗi thành phần u_i ; tiếp theo là $C(1, \dots, 1, u_i, 1, \dots, 1) = u_i$ với mọi $i \in \{1, \dots, d\}$ và $u_i \in [0, 1]$; cuối cùng là phải thỏa mãn bất đẳng thức hình chữ nhật với mọi $(a_1, \dots, a_d)$ và $(b_1, \dots, b_d) \in [0, 1]^d$ thỏa $a_i \leq b_i$, ta có:

$$\sum_{i_1=1}^2 \dots \sum_{i_d=1}^2 (-1)^{i_1+\dots+i_d} C(u_{1i_1}, \dots, u_{di_d}) \geq 0 \quad (6)$$

Trong đó $u_{j1} = a_j$ và $u_{j2} = b_j$ với mọi $j \in \{1, \dots, d\}$.

Đối với thuộc tính biên, với bất kỳ số nguyên k nào thỏa mãn $2 \leq k < d$, các phân phối biên k -chiều của một Copula d -chiều thì bản thân chúng cũng là các Copula. Nếu ta gọi G là một hàm phân phối và G^{-1} là nghịch đảo tổng quát của G , tức là hàm $G^{-1}(y) = \inf\{x : G(x) \geq y\}$, thì ta có các biến đổi thành phần. Đầu tiên là biến đổi phân vị, nếu $U \sim U(0, 1)$ có phân phối đều tiêu chuẩn thì $P(G^{-1}(U) \leq x) = G(x)$. Tiếp theo là biến đổi xác suất, nếu Y có phân phối tích lũy G , trong đó G là một hàm phân phối đơn biến liên tục, thì $G(Y) \sim U(0, 1)$.

Định lý Sklar: Định lý này được Sklar giới thiệu vào năm 1959, là định lý quan trọng nhất trong nghiên cứu về Copula và đóng vai trò nền tảng trong việc xây dựng các hàm phân phối đa biến. Định lý thiết lập mối quan hệ giữa hàm phân phối đồng thời F và các hàm phân phối biên $F_1, \dots, F_d$ thông qua một hàm Copula C . Về sự tồn tại, với bất kỳ hàm phân phối đồng thời F có biên $F_1, \dots, F_d$ luôn tồn tại một Copula $C : [0, 1]^d \rightarrow [0, 1]$ sao cho với mọi $x_1, \dots, x_d$ trong $\bar{R}$, ta có:

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d)) \quad (7)$$

Về tính duy nhất, nếu các biên $F_1, \dots, F_d$ là liên tục thì Copula C là duy nhất. Nếu các biên không liên tục (ví dụ phân phối rời rạc), Copula C vẫn tồn tại nhưng chỉ được xác định duy nhất trên phạm vi giá trị của các biên ($\text{Ran}F_1 \times \dots \times \text{Ran}F_d$), với $\text{Ran}F_i = F_i(\bar{R})$ biểu thị phạm vi giá trị mà hàm phân phối biên F_i có thể nhận được. Chiều ngược lại mang tính hướng tổng quát, nếu C là một Copula và $F_1, \dots, F_d$ là các hàm phân phối đơn biến, thì hàm F được xác định theo công thức trên chắc chắn là một hàm phân phối đồng thời hợp lệ với các biên chính là $F_1, \dots, F_d$. Mệnh đề tiếp theo chỉ ra rằng nếu T liên tục thì $T \circ T^{-1}(y) = y$. Từ một hàm phân phối đồng thời F có các biên liên tục, bằng cách sử dụng các hàm ngược F_i^{-1} tại $x_i = F_i^{-1}(u_i)$, với $0 \leq u_i \leq 1$, $i = 1, \dots, d$, ta thu được công thức:

$$C(u_1, \dots, u_d) = F(F_1^{-1}(u_1), \dots, F_d^{-1}(u_d)) \quad (8)$$

Công thức này cho thấy Copula diễn tả sự phụ thuộc trên thang đo phân vị.

Ý nghĩa của định lý trong quản trị rủi ro là rất lớn. Định lý cho phép nhà quản lý rủi ro tách biệt việc mô hình hóa hành vi biên của từng yếu tố rủi ro riêng lẻ khỏi việc mô hình hóa cấu trúc phụ thuộc giữa chúng. Sự linh hoạt này giúp nhà nghiên cứu có thể tự do kết hợp các loại phân phối biên khác nhau (như normal, t-Student, Pareto) với các cấu trúc phụ thuộc khác nhau nhằm tạo ra các mô hình phân phối đa biến phức tạp và thực tế hơn. Ngoài ra, khi ứng dụng trong các kịch bản cực đoan, Copula giúp mô hình hóa sự phụ thuộc của các kết quả cực đoan (như trong tính toán Value-at-Risk), điều mà các thước đo tương quan tuyến tính truyền thống thực hiện không tốt. Khi vectơ ngẫu

nhien X có phân phối tích lũy đồng thời F với các phân phối biên liên tục $F_1, \dots, F_d$, thì Copula của F (hoặc X) là hàm phân phối đa biến C của $(F_1(X_1), \dots, F_d(X_d))$.

Tính bất biến: Copula của một phân phối sẽ không thay đổi dưới các phép biến đổi tăng nghiêm ngặt của các biến biên. Điều này có nghĩa là cấu trúc phụ thuộc (được biểu diễn bởi Copula) tách biệt hoàn toàn với hình dạng của các phân phối biên riêng lẻ. Chúng ta có thể thay đổi thang đo của từng tài sản mà không làm thay đổi bản chất mối quan hệ phụ thuộc giữa chúng. Mệnh đề cụ thể phát biểu rằng: Gọi $(X_1, \dots, X_d)$ là một vectơ ngẫu nhiên với các biên liên tục và Copula C , gọi $T_1, \dots, T_d$ là các hàm tăng ngặt. Khi đó $(T_1(X_1), \dots, T_d(X_d))$ cũng có Copula là C .

Để chứng minh, đầu tiên biến đổi $T_i(X_i)$ có hàm phân phối liên tục $\bar{F}_i(y) := F_i \circ T_i^{-1}(y)$. Để thấy điều này, áp dụng mệnh đề $T \circ T^{-1}(y) \geq y$ ta có:

$$\bar{F}_i(y) = P(X_i \leq T_i^{-1}(y)) = P(T_i^{-1} \circ T_i(X_i) \leq T_i^{-1}(y))$$

Vì T_i^{-1} là một phép biến đổi tăng, chúng ta sử dụng bổ đề: Nếu F là hàm phân phối tích lũy của biến ngẫu nhiên X , thì $P(F(X) \leq F(x)) = P(X \leq x)$. Ta được:

$$\bar{F}_i(y) = P(T_i(X_i) \leq y) + P(X_i = T_i^{-1}(y), T_i(X_i) > y)$$

Nhưng xác suất thứ hai ở vế phải bằng không vì F_i liên tục. Vì C là Copula của X , nên có thể tính toán rằng:

$$C(u_1, \dots, u_d) = P(F_1(X_1) \leq u_1, \dots, F_d(X_d) \leq u_d) = P(\bar{F}_1(T_1(X_1)) \leq u_1, \dots, \bar{F}_d(T_d(X_d)) \leq u_d)$$

Vì $\bar{F}_i \circ T_i(x) = F_i \circ T_i^{-1} \circ T_i(x) = F_i(x)$ theo mệnh đề đã nêu, suy ra C cũng là Copula của $(T_1(X_1), \dots, T_d(X_d))$.

Giới hạn Fréchet: Đối với mọi Copula $C(u_1, \dots, u_d)$, chúng ta luôn có các giới hạn biên sau:

$$\max \left\{ \sum_{i=1}^d u_i + 1 - d, 0 \right\} \leq C(u) \leq \min\{u_1, \dots, u_d\} \quad (9)$$

Mặc dù đưa ra các giới hạn Fréchet cho một Copula, các giới hạn Fréchet có thể đưa ra cho bất kỳ hàm phân phối đa biến nào. Đối với một hàm phân phối tích lũy đa biến F với các biên $F_1, \dots, F_d$, chúng ta thiết lập bằng lập luận tương tự là:

$$\max \left\{ \sum_{i=1}^d F_i(x_i) + 1 - d, 0 \right\} \leq F(x) \leq \min\{F_1(X_1), \dots, F_d(X_d)\} \quad (10)$$

Vì vậy chúng ta có các giới hạn cho F theo các phân phối biên riêng lẻ của nó.

II.2.2 Các ví dụ của Copula

Các Copula cơ bản: Copula độc lập (Π) xuất hiện khi các biến ngẫu nhiên liên tục là độc lập nếu và chỉ nếu cấu trúc phụ thuộc của chúng được mô tả bởi công thức $\Pi(u_1, \dots, u_d) = \prod_{i=1}^d u_i$. Copula đồng biến (M) là giới hạn trên Fréchet, được định nghĩa là $M(u_1, \dots, u_d) = \min\{u_1, \dots, u_d\}$, đại diện cho sự phụ thuộc thuận hoàn hảo khi các biến là hàm tăng nghiêm ngặt của nhau. Copula nghịch biến (W) là giới hạn dưới Fréchet, xác định bởi $W(u_1, u_2) = \max\{u_1 + u_2 - 1, 0\}$, chỉ áp dụng cho trường hợp hai chiều và đại diện cho sự phụ thuộc nghịch hoàn hảo.

Các Copula ẩn: Gauss Copula được trích xuất từ phân phối chuẩn đa biến và được tham số hóa bởi ma trận tương quan. Đặc điểm quan trọng là nó không có phụ thuộc đuôi, nghĩa là các sự kiện cực đoan có xu hướng xảy ra độc lập trong các biến. Ngược lại, Student t Copula được trích xuất từ phân phối t đa biến. Khác với Gauss Copula, t Copula có phụ thuộc đuôi ở cả hai phía, khiến nó phù hợp hơn để mô phỏng các rủi ro cực đoan xảy ra đồng thời.

Các Copula hiển (tường minh): Đặc điểm chính của nhóm Copula hiển là chúng có một công thức giải tích đơn giản, khác với Copula ẩn vốn phải trải qua tính toán tích phân từ phân phối đa biến. Chúng ta có thể đặt các giá trị $u_1, \dots, u_d$ trực tiếp vào công thức để tính ra kết quả. Cấu trúc hàm sinh của đa số các Copula hiển phổ biến thuộc họ Archimedean Copulas, được xây dựng dựa trên một hàm số đơn biến ϕ gọi là hàm sinh, công thức và tính chất chuyên sâu sẽ được phân tích ở các mục sau.

Các biến thể nâng cao: Skewed t Copula (Copula t lệch) là một phiên bản không đối xứng của t Copula, cho phép các mức độ phụ thuộc đuôi khác nhau ở các góc đối diện của phân phối. Grouped t Copula (Copula t phân nhóm) cho phép các nhóm tài sản khác nhau trong một danh mục có các mức độ phụ thuộc đuôi khác nhau thông qua việc tham số hóa bậc tự do ν khác nhau. Galambos Copula là một ví dụ về Copula cực đoan, mô tả cấu trúc phụ thuộc của các giá trị cực đại đa biến. Việc lựa chọn giữa các loại Copula này rất quan trọng vì chúng dẫn đến các đánh giá rủi ro khác nhau, đặc biệt là khi tính toán xác suất xảy ra các biến cố cực đoan đồng thời.

II.2.3 Phân phối meta

Phân phối meta là các hàm phân phối đa biến được xây dựng bằng cách kết hợp một Copula cụ thể với các phân phối biên tùy ý. Cơ sở xây dựng dựa trên định lý Sklar, nếu ta chọn một Copula C và các hàm phân phối biên $F_1, \dots, F_d$ thì hàm phân phối đa biến F được xác định bởi công thức:

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d)) \quad (11)$$

Hàm số này chắc chắn là một hàm phân phối đồng thời hợp lệ với các biến chính là $F_1, \dots, F_d$.

Các ví dụ điển hình bao gồm phân phối Meta-Gaussian, sử dụng Gauss Copula kết hợp với các phân phối biên bất kỳ. Phân phối Meta- t sử dụng t Copula kết hợp với các biến tùy ý; phân phối này thường được quan tâm hơn Meta-Gaussian vì nó có khả năng mô tả phụ thuộc đuôi. Ngoài ra còn có phân phối Meta-Clayton và Meta-Gumbel được tạo ra bằng cách sử dụng Copula Clayton hoặc Gumbel với các phân phối biên do người dùng tự lựa chọn.

Ưu điểm của cấu trúc này trong quản trị rủi ro nằm ở tính linh hoạt, cho phép nhà quản lý rủi ro tách việc mô hình hóa hành vi của từng tài sản riêng lẻ khỏi việc mô hình hóa cấu trúc phụ thuộc (Copula). Bên cạnh đó, nó hỗ trợ phân tích độ nhạy một cách tối ưu; phương pháp này cho phép thực hiện các thử nghiệm kiểm tra sức chịu tải bằng cách thay đổi Copula (ví dụ: dịch chuyển từ Meta-Gaussian không có phụ thuộc đuôi sang Meta- t có phụ thuộc đuôi mạnh) trong khi vẫn giữ nguyên các phân phối biên để xem rủi ro tổng thể thay đổi như thế nào.

II.2.4 Các đặc tính khác của Copula

Copula sống sót: Trong khi một Copula thông thường kết nối các hàm phân phối tích lũy, Copula sống sót ($\hat{C}$) kết nối các hàm sống sót biên để tạo thành hàm sống sót đồng thời thông qua công thức:

$$\bar{F}(x_1, \dots, x_d) = \hat{C}(\bar{F}_1(x_1), \dots, \bar{F}_d(x_d)) \quad (12)$$

Về mặt toán học, nếu vectơ U có phân phối Copula C , thì Copula sống sót của C chính là hàm phân phối của vectơ $1 - U$, trong đó $U := (F_1(X_1), \dots, F_d(X_d))$. Mối liên hệ trong trường hợp hai chiều được biểu diễn như sau:

$$\hat{C}(1 - u_1, 1 - u_2) = 1 - u_1 - u_2 + C(u_1, u_2) \quad (13)$$

Tính đối xứng xuyên tâm: Một vectơ ngẫu nhiên được gọi là đối xứng xuyên tâm quanh điểm a nếu $X - a = a - X$. Đối với Copula, tính chất này có nghĩa là $U = 1 - U$. Khi một Copula có tính đối xứng xuyên tâm, Copula sống sót của nó sẽ bằng chính nó ($\hat{C} = C$). Ví dụ điển hình là các Copula của phân phối elip (như Gauss và t) đều có tính đối xứng xuyên tâm, trong khi các Copula Archimedean như Gumbel và Clayton thì không.

Phân phối có điều kiện của Copula: Đặc tính này cho phép tính xác suất để một biến vượt qua một ngưỡng nhất định khi biết giá trị cụ thể của biến kia (trên thang đo phân vị). Trong hai chiều, hàm phân phối có điều kiện của U_2 khi biết $U_1 = u_1$ được tính bằng đạo hàm riêng:

$$C_{U_2|U_1}(u_2 | u_1) = P(U_2 \leq u_2 | U_1 = u_1) = \lim_{\delta \rightarrow 0} \frac{C(u_1 + \delta, u_2) - C(u_1, u_2)}{\delta} = \frac{\partial}{\partial u_1} C(u_1, u_2) \quad (14)$$

Mật độ Copula: Hầu hết các Copula tham số thường dùng đều có mật độ (ngoại trừ các trường hợp phụ thuộc hoàn hảo như tính đồng điệu). Mật độ Copula được xác định bằng đạo hàm bậc d của hàm $C(u_1, \dots, u_d)$ theo tất cả các thành phần. Mật độ này rất quan trọng trong việc ước lượng tham số bằng phương pháp tối đa hóa xác suất. Hình ảnh mật độ giúp trực quan hóa cấu trúc phụ thuộc; ví dụ, mật độ của t Copula tập trung nhiều khối lượng xác suất ở các góc hơn so với Gauss Copula do có hiện tượng phụ thuộc đuôi.

Tính trao đổi được: Một Copula được gọi là trao đổi được nếu giá trị của nó không đổi khi ta hoán vị các đối số, thể hiện qua công thức $C(u_1, \dots, u_d) = C(u_{\pi(1)}, \dots, u_{\pi(d)})$ với mọi hoán vị π . Hầu hết các Copula Archimedean chuẩn là trao đổi được, trong khi Gauss và t Copula chỉ trao đổi được khi ma trận tương quan có các hệ số tương quan cặp bằng nhau.

Đặc tính co giãn của Copula giá trị cực trị: Các Copula giá trị cực trị có một đặc tính tỷ lệ đặc biệt, thỏa mãn hệ thức $C(u^t) = C^t(u)$ với mọi $t > 0$. Đặc tính này phản ánh cấu trúc phụ thuộc giới hạn của các giá trị cực đại trong các khối dữ liệu.

II.2.5 Sự phụ thuộc hoàn hảo

Sự phụ thuộc hoàn hảo được mô tả thông qua hai trạng thái cực đoan của cấu trúc phụ thuộc: sự đồng biến và sự nghịch biến. Các khái niệm này liên quan chặt chẽ đến các giới hạn Fréchet của Copula.

Sự đồng biến (Phụ thuộc thuận hoàn hảo): Các biến ngẫu nhiên $X_1, \dots, X_d$ được gọi là đồng biến nếu chúng có Copula là giới hạn trên Fréchet:

$$M(u_1, \dots, u_d) = \min\{u_1, \dots, u_d\} \quad (15)$$

Đặc điểm hình học chỉ ra rằng các điểm dữ liệu tuân theo cấu trúc đồng biến sẽ nằm hoàn toàn trên một đường chéo tăng trong không gian đa biến. Về tính chất toán học, các biến số đồng biến thực chất là các hàm tăng của cùng một biến ngẫu nhiên duy nhất Z . Đối với các biến có hàm phân phối liên tục, X_i và X_j là đồng biến khi và chỉ khi tồn tại một phép biến đổi tăng ngặt T sao cho $X_j = T(X_i)$ hầu chắc chắn. Một đặc tính quan trọng của rủi ro đồng biến là giá trị phân vị có tính cộng tính, tức là VaR của tổng của rủi ro đồng biến bằng tổng các VaR của từng rủi ro thành phần.

Sự nghịch biến (Phụ thuộc nghịch hoàn hảo): Hai biến ngẫu nhiên X_1 và X_2 được gọi là nghịch biến nếu chúng có Copula là giới hạn dưới Fréchet:

$$W(u_1, u_2) = \max\{u_1 + u_2 - 1, 0\} \quad (16)$$

Đặc điểm của trường hợp này là biến này là hàm giảm nghiêm ngặt của biến kia hầu chắc chắn. Tuy nhiên, cấu trúc này có hạn chế về chiều: khác với sự đồng biến, khái niệm nghịch biến không thể mở rộng cho không gian ba chiều trở lên ($d > 2$). Giới hạn dưới Fréchet W không còn là một Copula hợp lệ khi số chiều lớn hơn hai.

Ý nghĩa trong quản trị rủi ro: Mọi Copula bất kỳ $C(u_1, \dots, u_d)$ luôn nằm trong khoảng giới hạn Fréchet $W \leq C \leq M$ (với W chỉ áp dụng cho hai chiều). Trong kỹ thuật Stress-testing, sự đồng biến thường đại diện cho kịch bản rủi ro tập trung cao nhất đối với các thước đo rủi ro hiệp biến như Expected Shortfall (ES), vì khi đó đa dạng hóa không mang lại lợi ích giảm rủi ro. Đối với mối quan hệ tương quan tuyến tính, hệ số tương quan tuyến tính đạt giá trị cực đại khi các biến đồng biến và đạt giá trị cực tiểu khi chúng nghịch biến (với điều kiện các biến có cùng kiểu phân phối).

II.3 Các thước đo sự phụ thuộc đuôi

II.3.1 Tương quan tuyến tính

Định nghĩa và cơ sở toán học:

- Hệ số tương quan (ρ) giữa hai biến ngẫu nhiên X_1 và X_2 được tính bằng tỷ số giữa hiệp phương sai và tích các độ lệch chuẩn của chúng:

$$\rho(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)\text{var}(X_2)}} \quad (17)$$

- Đối với một vectơ ngẫu nhiên đa biến X , ma trận tương quan $P = \rho(X)$ có các phần tử tại vị trí (i, j) là tương quan cặp giữa X_i và X_j . Ma trận này luôn có tính chất xác định dương hoặc ít nhất là nửa xác định dương.

Các đặc tính chính:

- Hệ số tương quan tuyến tính luôn nằm trong khoảng $[-1, 1]$. Khi $\rho = 1$, hai biến có sự phụ thuộc tuyến tính thuận hoàn hảo, và khi $\rho = -1$, hai biến có sự phụ thuộc tuyến tính nghịch hoàn hảo.
- Một thuộc tính quan trọng khác là tính bất biến: tương quan tuyến tính có tính bất biến dưới các phép biến đổi tuyến tính tăng nghiêm ngặt. Tuy nhiên, nó không bất biến đối với các phép biến đổi phi tuyến.

Hạn chế và những cạm bẫy: Tương quan chỉ được xác định khi các biến có phương sai hữu hạn, điều này gây khó khăn với các rủi ro có đuôi nặng (như rủi ro hoạt động) có phương sai vô hạn. Mối liên hệ giữa tương quan và độc lập cũng dễ gây nhầm lẫn: độc lập dẫn đến tương quan bằng 0, nhưng ngược lại không luôn đúng. Các biến không tương quan vẫn có thể phụ thuộc chặt chẽ về mặt cấu trúc trong các mô hình phi Gaussian. Bên cạnh đó, mô hình này còn vấp phải ba cạm bẫy lớn trong quản trị rủi ro:

- **Cạm bẫy 1 (Xác định phân phối):** Các phân phối biên và tương quan cặp không đủ để xác định phân phối đồng thời của một vectơ ngẫu nhiên.
- **Cạm bẫy 2 (Tương quan có thể đạt được):** Với các phân phối biên cho trước, dải tương quan đạt được thực tế có thể hẹp hơn khoảng $[-1, 1]$. Ngay cả khi hai biến phụ thuộc thuận mạnh nhất, tương quan tuyến tính vẫn có thể rất thấp.
- **Cạm bẫy 3 (Rủi ro danh mục):** Một quan niệm sai lầm phổ biến là cho rằng rủi ro của một danh mục là tệ nhất khi tương quan đạt cực đại. Thực tế, đối với các phân phối không đối xứng, danh mục có tương quan thấp hơn đôi khi lại tạo ra tổn thất cực đoan lớn hơn so với tương quan hoàn hảo.

Mặc dù tương quan tuyến tính là một tham số tự nhiên trong các mô hình elip, nó không phản ánh được các cấu trúc phụ thuộc phi tuyến hoặc phụ thuộc đuôi. Do đó, các nhà quản lý rủi ro thường hướng tới sử dụng Copula để tách biệt hành vi biến của tài sản khỏi cấu trúc phụ thuộc của chúng, cho phép đánh giá chính xác hơn các kịch bản rủi ro cực đoan.

II.3.2 Tương quan hạng

Tương quan hạng là các thước đo phụ thuộc vô hướng chỉ phụ thuộc vào Copula của phân phối đa biến mà không bị ảnh hưởng bởi các phân phối biên. Các thuộc tính chung bao gồm tính bất biến đối với các phân phối biên liên tục dưới các phép biến đổi đồng tăng nghiêm ngặt; phạm vi giá trị luôn nằm ở đoạn $[-1, 1]$; trạng thái cực đoan đạt giá trị 1 khi các biến là đồng biến và đạt -1 khi chúng nghịch biến; và thuộc tính độc lập khi hai biến độc lập sẽ có tương quan hạng bằng 0 (tuy nhiên giá trị bằng 0 không nhất thiết hàm ý sự độc lập). Đối với nhóm phân phối elip và các Copula hỗn hợp phương sai chuẩn, hệ số Kendall's Tau có mối quan hệ trực tiếp lý tưởng với tham số tương quan tuyến tính ρ qua hệ thức:

$$\rho_\tau(X_1, X_2) = \frac{2}{\pi} \arcsin(\rho) \quad (18)$$

Mối liên hệ chức năng này rất mạnh mẽ, cho phép các nhà quản lý rủi ro có thể ước lượng ma trận tương quan ρ một cách vững chắc từ mẫu dữ liệu thực tế, ngay cả khi gặp phải

hiện tượng đuôi nặng hoặc phương sai vô hạn, vốn là những trường hợp mà cách tính tương quan tuyến tính trực tiếp hoạt động kém hiệu quả.

Bên cạnh Kendall's Tau, Spearman's Rho (ρ_s) là một thước đo quan trọng khác dựa trên sự biến đổi xác suất của các biến ngẫu nhiên qua các hàm biên phân phối liên tục, cụ thể $\rho_s(X_1, X_2) = \rho(F_1(X_1), F_2(X_2))$, biểu diễn bằng tích phân qua Copula như sau:

$$\rho_s(X_1, X_2) = 12 \int_0^1 \int_0^1 (C(u_1, u_2) - u_1 u_2) du_1 du_2 \quad (19)$$

Kendall's Tau (ρ_τ): Thước đo này đo lường mức độ hòa hợp giữa các cặp biến ngẫu nhiên. Hai điểm (x_1, x_2) và $(\bar{x}_1, \bar{x}_2)$ được gọi là hòa hợp nếu $(x_1 - \bar{x}_1)(x_2 - \bar{x}_2) > 0$ và bất hòa nếu tích này nhỏ hơn 0. Công thức tính được xác định qua biểu thức:

$$\rho_\tau(X_1, X_2) = P((X_1 - \bar{X}_1)(X_2 - \bar{X}_2) > 0) - P((X_1 - \bar{X}_1)(X_2 - \bar{X}_2) < 0) \quad (20)$$

Trong đó $(\bar{X}_1, \bar{X}_2)$ là bản sao độc lập của (X_1, X_2) . Khi tính toán qua Copula, công thức trở thành:

$$\rho_\tau(X_1, X_2) = 4 \int_0^1 \int_0^1 C(u_1, u_2) dC(u_1, u_2) - 1 \quad (21)$$

Ứng dụng của Kendall's Tau thường được dùng để hiệu chuẩn các tham số của Copula elip hoặc Copula Archimedean.

Ý nghĩa trong quản trị rủi ro: Đầu tiên là hiệu chuẩn Copula, các nhà quản lý rủi ro sử dụng tương quan hạng mẫu để tìm ra tham số phù hợp cho các mô hình copula khi dữ liệu đa biến dị hạn chế. Tiếp theo là tách biệt rủi ro: Nó giúp nghiên cứu riêng biệt đặc tính của từng tài sản (biên) và cấu trúc phụ thuộc (hạng), hỗ trợ xây dựng các kịch bản kiểm tra sức chịu tải hiệu quả hơn.

II.3.3 Các hệ số phụ thuộc đuôi

Trong quản trị rủi ro định lượng, các hệ số phụ thuộc đuôi là thước đo mức độ phụ thuộc giữa các biến ở các cực đoan đồng thời của một phân phối đa biến. Đây là các đại lượng không đổi khi phụ thuộc vào Copula của cặp biến ngẫu nhiên đó.

Định nghĩa các hệ số: Có hai hệ số chính được sử dụng để đo lường sự phụ thuộc tại các vùng cực đoan:

- Hệ số phụ thuộc đuôi trên (λ_u) đo lường xác suất một biến vượt qua một ngưỡng phân vị rất cao, với điều kiện biến kia cũng đã vượt qua ngưỡng đó. Công thức được xác định là giới hạn:

$$\lambda_u = \lim_{q \rightarrow 1^-} P(X_2 > F_2^{-1}(q) | X_1 > F_1^{-1}(q)) \quad (22)$$

Nếu $\lambda_u > 0$, cặp biến số có sự phụ thuộc đuôi trên (phụ thuộc cực đoan); nếu $\lambda_u = 0$, chúng độc lập tiệm cận ở đuôi trên.

- Hệ số phụ thuộc đuôi dưới (λ_l) tương tự đo lường xác suất một biến nhận giá trị cực thấp khi biến kia cũng đang ở vùng cực thấp. Công thức là:

$$\lambda_l = \lim_{q \rightarrow 0^+} P(X_2 \leq F_2^{-1}(q) | X_1 \leq F_1^{-1}(q)) \quad (23)$$

Đối với các Copula có tính đối xứng xuyên tâm như Gauss hay t , ta luôn có $\lambda_l = \lambda_u$.

Đặc điểm của các loại Copula phổ biến: Mỗi loại Copula mang lại các đặc tính phụ thuộc đuôi rất khác nhau, ảnh hưởng trực tiếp đến việc đánh giá rủi ro hệ thống:

- Gauss: $\lambda_u = \lambda_l = 0$. Đặc điểm rủi ro là độc lập tiệm cận ở cả hai đuôi, có thể đánh giá thấp rủi ro các biến cố cực đoan xảy ra cùng lúc.
- Student t : $\lambda_u = \lambda_l > 0$. Đặc điểm rủi ro là có phụ thuộc đuôi ở cả hai phía, phụ thuộc tăng khi bậc tự do ν giảm hoặc tương quan ρ tăng.
- Gumbel: $\lambda_u = 2 - 2^{1/\theta}$, $\lambda_l = 0$. Đặc điểm rủi ro là chỉ phụ thuộc đuôi trên, thường dùng mô hình hóa các khoản thua lỗ lớn đồng thời.
- Clayton: $\lambda_u = 0$, $\lambda_l = 2^{-1/\theta}$. Đặc điểm rủi ro là chỉ phụ thuộc đuôi dưới.
- Frank: $\lambda_u = \lambda_l = 0$. Đặc điểm rủi ro là không có phụ thuộc đuôi ở bất kỳ phía nào.

Ý nghĩa trong quản trị rủi ro: Sự độc lập tiệm cận của Gauss Copula cho thấy việc sử dụng Gauss Copula cho sự kiện rủi ro cao, ngay cả khi có hệ số tương quan rất lớn, khi tiến sâu vào vùng đuôi cực đoan, các biến cố trong mô hình Gaussian có xu hướng xảy ra độc lập, dẫn đến việc đánh giá thấp xác suất xảy ra khủng hoảng đồng thời. Ngược lại, việc sử dụng Student t Copula được ưa chuộng hơn trong thực tế vì nó ghi nhận hiện tượng xảy ra các tài sản cùng sụt giảm mạnh. Ví dụ, xác suất xảy ra biến cố cực đoan đồng thời trong mô hình t có thể cao gấp nhiều lần so với mô hình Gaussian. Đối với phân phối elip, trọng tâm phụ thuộc đuôi được quyết định bởi đuôi của biến trộn; nếu biến trộn có phân phối đuôi nặng (như nghịch đảo Gamma trong trường hợp phân phối t), chúng ta sẽ thu được phụ thuộc đuôi.

II.4 Các Copula hỗn hợp chuẩn

II.4.1 Phụ thuộc đuôi

Phụ thuộc đuôi của các Copula hỗn hợp chuẩn là một yếu tố then chốt để hiểu cách các biến cố cực đoan liên kết với nhau trong quản trị rủi ro.

Đặc tính chung và tính đối xứng: Các Copula hỗn hợp phương sai chuẩn có tính đối xứng xuyên tâm. Do đó, hệ số phụ thuộc đuôi trên (λ_u) và đuôi dưới (λ_l) luôn bằng nhau: $\lambda_u = \lambda_l = \lambda$. Vì các Copula này thường có tính trao đổi được, hệ số phụ thuộc đuôi có thể được tính đơn giản qua giới hạn xác suất có điều kiện: $\lambda = 2 \lim_{q \rightarrow 0+} P(U_2 \leq q | U_1 = q)$.

Sự khác biệt giữa các Copula Gauss và Copula Student t :

- Gauss Copula: Có đặc tính độc lập tiệm cận, nghĩa là $\lambda = 0$. Dù hệ số tương quan có cao đến đâu, khi tiến sâu vào vùng đuôi cực đoan, các biến cố có xu hướng xảy ra độc lập. Việc sử dụng Copula này có thể dẫn đến việc đánh giá thấp rủi ro hệ thống trong các cuộc khủng hoảng.
- Student t Copula: Có phụ thuộc đuôi ($\lambda > 0$) ở cả hai phía. Hệ số này phụ thuộc vào bậc tự do (ν) và tương quan (ρ) theo công thức:

$$\lambda = 2t_{\nu+1} \left(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right) \quad (24)$$

Phụ thuộc đuôi sẽ tăng lên khi bậc tự do ν giảm (đuôi nặng hơn) hoặc hệ số tương quan ρ tăng. Ngay cả khi tương quan bằng 0 hoặc âm, Copula t vẫn có thể phụ thuộc đuôi dương.

Vai trò của biến trộn W : Yếu tố quyết định một Copula hỗn hợp phương sai chuẩn có phụ thuộc đuôi hay không nằm ở đuôi của phân phối biến trộn W . Nếu W có phân phối với đuôi lũy thừa (như nghịch đảo Gamma trong trường hợp phân phối t), Copula sẽ có phụ thuộc đuôi. Ngược lại, nếu W không có đuôi lũy thừa (như trong phân phối Hyperbolic), Copula sẽ độc lập tiệm cận ở các đuôi, tương tự như Copula Gauss.

Các biến thể nâng cao: Ngoài ra, còn có các biến thể nâng cao của Copula t được thiết kế để mô hình hóa các cấu trúc phụ thuộc phức tạp hơn: Skewed t Copula (Copula t lệch): Cho phép các mức độ phụ thuộc đuôi khác nhau ở các góc đối diện của phân phối (ví dụ: rủi ro cùng sụt giảm mạnh hơn là cùng tăng mạnh), phá vỡ tính đối xứng xuyên tâm. Và Grouped t Copula (Copula t phân nhóm): Cho phép các nhóm tài sản khác nhau trong một danh mục có các mức độ phụ thuộc đuôi khác nhau (thông qua các tham số ν riêng biệt cho từng nhóm).

II.4.2 Tương quan hạng

Tương quan hạng của các Copula hỗn hợp chuẩn là các thước đo phụ thuộc vô hướng chỉ phụ thuộc vào cấu trúc phụ thuộc (Copula) mà không bị ảnh hưởng bởi các phân phối biên.

Kendall's Tau (ρ_τ): Đây là thước đo quan trọng nhất đối với các Copula hỗn hợp phương sai chuẩn vì nó có mối quan hệ trực tiếp và đơn giản với tham số tương quan. Công thức tổng quát như ở mục II.3.2, đối với hầu hết các Copula hỗn hợp phương sai chuẩn (thuộc họ phân phối elip), mối quan hệ giữa Kendall's Tau và tham số tương quan tuyến tính ρ được xác định bởi:

$$\rho_\tau(X_1, X_2) = \frac{2}{\pi} \arcsin(\rho)$$

Phạm vi áp dụng của công thức này áp dụng chính xác cho cả Gauss Copula và Student t Copula. Ý nghĩa ước lượng của mối quan hệ này rất mạnh mẽ; nhà quản lý rủi ro có thể ước lượng ma trận tương quan ρ một cách mạnh mẽ từ Kendall's Tau mẫu, ngay cả khi dữ liệu có đuôi nặng hoặc phương sai vô hạn, vốn là những trường hợp mà tương quan tuyến tính tính toán trực tiếp hoạt động kém hiệu quả.

Spearman's Rho (ρ_s): Mối quan hệ Spearman's Rho với tham số tương quan phức tạp hơn và không đồng nhất giữa các loại Copula hỗn hợp chuẩn. Đối với Gauss Copula, Spearman's rho có công thức dạng đóng:

$$\rho_s(X_1, X_2) = \frac{6}{\pi} \arcsin\left(\frac{\rho}{2}\right) \quad (25)$$

Giá trị này rất gần với tham số ρ ($\rho_s \approx \rho$) với sai số tối đa không quá 0.0181. Đối với các Copula hỗn hợp chuẩn khác (như t Copula), mối quan hệ trên không nhất thiết đúng cho tất cả các phân phối elip. Hiện chưa có công thức đơn giản tương tự cho t Copula, mặc dù các nghiên cứu mô phỏng cho thấy sai số xấp xỉ $\rho_s \approx \rho$ ở mức không đáng kể, dù lớn hơn so với trường hợp Gauss.

II.5 Các Copula Archimedean

Họ Copula Archimedean là một nhóm các cấu trúc phụ thuộc được sử dụng rộng rãi trong các ứng dụng tài chính và quản trị rủi ro nhờ vào công thức dạng đóng đơn giản và khả năng nắm bắt các loại phụ thuộc khác nhau.

Định nghĩa và hàm sinh: Một Copula Archimedean hai chiều được xác định thông qua một hàm số ϕ gọi là hàm sinh, công thức tổng quát là:

$$C(u_1, u_2) = \phi^{[-1]}(\phi(u_1) + \phi(u_2)) \quad (26)$$

Trong đó ϕ là hàm liên tục, giảm nghiêm ngặt và lồi trên thỏa mãn $\phi(1) = 0$. Ký hiệu $\phi^{[-1]}$ được định nghĩa là một nghịch đảo giả của ϕ , có dạng:

$$\phi^{[-1]} = \begin{cases} \phi^{-1}(t), & 0 \leq t \leq \phi(0) \\ 0, & \phi(0) < t \leq \infty \end{cases} \quad (27)$$

Nếu $\phi(0) = \infty$, hàm sinh được gọi là nghiêm ngặt và ta có thể dùng hàm nghịch đảo thông thường ϕ^{-1} .

Các ví dụ phổ biến:

- Gumbel Copula: Có hàm sinh $\phi(t) = (-\ln t)^\theta$, với $\theta \geq 1$. Nó đặc trưng bởi phụ thuộc đuôi trên.
- Clayton Copula: Có hàm sinh $\phi(t) = \frac{1}{\theta}(t^{-\theta} - 1)$ với $\theta > 0$ (trong trường hợp nghiêm ngặt). Nó đặc trưng bởi phụ thuộc đuôi dưới.
- Frank Copula: Có hàm sinh là $\phi(t) = -\ln\left(\frac{e^{-\theta t} - 1}{e^{-\theta} - 1}\right)$, với $\theta \in R$. Đây là loại Copula Archimedean duy nhất có tính đối xứng tâm và không phụ thuộc đuôi ở bất kỳ phía nào.
- Copula Clayton tổng quát: Có hàm sinh là $\phi(t) = \theta^{-\delta}(t^{-\theta} - 1)^\delta$, với $\theta > 0, \delta \geq 1$. Đây là một biến thể hai tham số có thể phụ thuộc ở cả hai đuôi.

Mở rộng đa biến và tính trao đổi được: Mở rộng một Copula Archimedean d chiều có thể được xây dựng theo công thức:

$$C(u_1, \dots, u_d) = \phi^{-1}(\phi(u_1) + \dots + \phi(u_d)) \quad (28)$$

Điều kiện tồn tại để công thức này tạo thành một Copula hợp lệ trong mọi số chiều d là hàm nghịch đảo ϕ^{-1} phải có tính đơn điệu hoàn toàn. Về tính trao đổi được, các Copula Archimedean đa biến tiêu chuẩn có tính trao đổi được, nghĩa là vai trò của các biến là như nhau. Tuy nhiên, ta có thể xây dựng các phiên bản không trao đổi được bằng cách áp dụng đệ quy các hàm sinh khác nhau để tạo cấu trúc phân nhóm.

Copula LT-Archimedean: Đây là một nhóm con quan trọng được xây dựng dựa trên biến đổi Laplace-Stieltjes (LT) của một hàm phân phối G . Hàm nghịch đảo của hàm sinh ϕ^{-1} chính là biến đổi Laplace của G . Cách tiếp cận này cho phép mô phỏng dễ dàng bằng cách sử dụng một biến nguyên trộn V có phân phối G (ví dụ: phân phối Gamma cho Clayton, hoặc phân phối ổn định định hướng cho Gumbel). Ứng dụng của nó rất hữu ích trong mô hình hóa rủi ro tín dụng danh mục, nơi biến V đóng vai trò là yếu tố rủi ro chung.

Thước đo phụ thuộc: Các thước đo rủi ro có thể được tính trực tiếp từ hàm sinh ϕ :

- Hệ số Kendall's tau (ρ_τ) được tính theo công thức:

$$\rho_\tau = 1 + 4 \int_0^1 \frac{\phi(t)}{\phi'(t)} dt \quad (29)$$

- Phụ thuộc đuôi: Các hệ số λ_u và λ_l được xác định dựa trên tham số θ của từng loại (ví dụ: $\lambda_u = 2 - 2^{1/\theta}$ cho Gumbel).

II.6 Hiện tượng đuôi nặng

Hiện tượng đuôi nặng:

- Định nghĩa: Một trong những hiện tượng phổ biến của các chuỗi lợi nhuận tài chính là chúng có phân phối nhọn hoặc đuôi nặng. Điều này có nghĩa là phân phối này hẹp hơn phân phối chuẩn ở phần trung tâm nhưng lại có phần đuôi dài và nặng hơn.
- Tốc độ suy giảm: Trong khi đuôi của phân phối chuẩn suy giảm cực nhanh theo hàm mũ, đuôi của lợi nhuận tài chính thường suy giảm chậm hơn theo quy luật lũy thừa.
- Hệ quả: Các sự kiện cực đoan (tổn thất lớn) xảy ra thường xuyên hơn nhiều so với dự báo của mô hình phân phối chuẩn. Ví dụ, trong cuộc khủng hoảng 2007–2009, nhiều biến động giá có xác suất xảy ra theo mô hình truyền thống là cực thấp (gần như bằng 0) nhưng thực tế đã xảy ra liên tục.

Sự hạn chế của các mô hình truyền thống: Các mô hình quản trị danh mục cổ điển (như lý thuyết hiện đại Markowitz) dựa trên các giả định đơn giản hóa để đạt được sự tối ưu về mặt toán học. Tuy nhiên, trong thực tế thị trường tài chính, các giả định này bộc lộ ba hạn chế cốt lõi sau:

- Đánh giá thấp rủi ro cực đoan: Việc sử dụng phân phối chuẩn (Gaussian) dẫn đến việc đánh giá thấp đuôi của phân phối tổn thất, từ đó làm giảm nhẹ mức độ rủi ro thực tế của danh mục đầu tư. Ngoài ra, các mô hình như VaR (Value-at-Risk) truyền thống thường chỉ bắt đầu phản ánh rủi ro đuôi khi sử dụng mức tin cậy rất cao (trên 99%), trong khi các mô hình đuôi nặng như phân phối t đã bộc lộ rủi ro này từ mức tin cậy thấp hơn.
- Khiếm khuyết của thước đo phương sai: Phương sai không phân biệt giữa sai lệch tích cực (lãi) và tiêu cực (lỗ), nó chỉ là thước đo tốt cho các phân phối gần như đối xứng, trong khi rủi ro tín dụng và rủi ro hoạt động thường có phân phối lệch mạnh. Để sử dụng phương sai, người ta phải giả định mô-men bậc hai tồn tại. Tuy nhiên, trong rủi ro hoạt động hoặc bảo hiểm, dữ liệu có thể có đuôi nặng đến mức phương sai là vô hạn, khiến thước đo này trở nên vô nghĩa.
- Vấn đề với quy tắc đa dạng hóa và phương sai: Trong các kịch bản có phân phối lệch hoặc đuôi rất nặng, VaR có thể không thỏa mãn tính cộng dưới. Điều này dẫn đến một nghịch lý: đa dạng hóa danh mục đôi khi lại làm tăng VaR thay vì giảm rủi ro. Nếu sử dụng VaR để đặt hạn mức cho các nhà giao dịch, nó có thể thúc đẩy họ xây dựng các danh mục tập trung quá mức vào một tài sản rủi ro duy nhất để tối ưu hóa lợi nhuận dưới ràng buộc VaR.

Khủng hoảng cộng hưởng và sự sụp đổ của sự phụ thuộc:

- Các mô hình truyền thống (như Gauss copula) thường giả định sự độc lập tiệm cận. Trong điều kiện bình thường, các tài sản có vẻ ít liên quan, nhưng trong các sự kiện khủng hoảng cộng hưởng, các nhân tố rủi ro thường biến động ngược chiều cùng lúc.
- Khi khủng hoảng xảy ra, các lập luận về đa dạng hóa danh mục có thể bị phá vỡ hoàn toàn do sự xuất hiện của hiện tượng phụ thuộc đuôi – nơi các tài sản cùng sụp đổ đồng thời. Việc sử dụng máy móc công thức Gauss copula để định giá các sản phẩm phức tạp như CDO được coi là một nguyên nhân gây ra thảm họa tài chính năm 2008.

Hướng đi mới trong quản trị rủi ro hiện đại: Để khắc phục, tài liệu đề xuất chuyển sang các phương pháp tiên tiến hơn:

- Sử dụng các phân phối đuôi nặng (như phân phối t) để mô hình hóa lợi nhuận tài chính, giúp đánh giá chính xác hơn rủi ro cực đoan.
- Áp dụng các Copula phức tạp hơn (như Copula Archimedean hoặc hỗn hợp) để nắm bắt tốt hơn sự phụ thuộc đuôi và mô hình hóa mối quan hệ giữa các tài sản trong các điều kiện thị trường khác nhau.
- Phát triển các thước đo rủi ro mới (như Expected Shortfall) thay vì VaR, vì chúng có tính cộng và phản ánh tốt hơn rủi ro trong các kịch bản đuôi nặng.

III Ứng dụng mô phỏng Monte Carlo từ Copula

Mô phỏng Monte Carlo dựa trên Copula là một công cụ mạnh mẽ trong quản trị rủi ro định lượng, giúp hiểu sâu hơn về cấu trúc phụ thuộc của các biến ngẫu nhiên. Kỹ thuật xây dựng mô hình đi từ dưới lên này cho phép các nhà quản lý rủi ro linh hoạt kết hợp cấu trúc phân phối của các biến biên độc lập với các mô hình Copula đặc trưng nhằm mô phỏng chính xác hành vi rủi ro toàn danh mục. Việc tạo lập các phân phối liên kết Meta như Meta-Gaussian hay Meta- t đóng vai trò cốt lõi phục vụ phân tích thử nghiệm và đánh giá mức độ nhạy cảm của hệ thống trước sự biến đổi từ các tham số phụ thuộc đuôi. Trong quản trị rủi ro tín dụng, mô phỏng Copula được ứng dụng để xác định phân phối tổn thất của danh mục vay hoặc trái phiếu thông qua việc mô phỏng thời gian vỡ nợ đồng thời của các đối tác, đây là phương pháp tiêu chuẩn để định giá các sản phẩm phái sinh tín dụng phức tạp như basket derivatives và các tầng của CDO (Collateralized Debt Obligations).

Hơn nữa, việc mô phỏng các cấu trúc này cho phép các nhà giao dịch tính toán tương quan tài sản ngầm định từ giá thị trường của các tầng CDO, giúp so sánh rủi ro giữa các điểm đỉnh kèm và nhóm tài sản khác nhau. Để cải thiện hiệu suất khi mô phỏng các biến cố cực đoan như tổn thất lớn trong các tầng CDO cao, kỹ thuật lấy mẫu ưu tiên thường được kết hợp với mô phỏng Copula để giảm biến số và tăng độ chính xác của ước lượng. Đối với các bài toán ước tính rủi ro đa kỳ hạn, mô phỏng Monte Carlo từ Copula cho phép xác định các thước đo rủi ro như Var và Expected Shortfall cho các kỳ hạn dài bằng các mô phỏng các đường dẫn thực tế của các yếu tố rủi ro thay vì dựa vào các quy tắc tỷ lệ đơn giản. Ngoài ra, trong các mô hình actuarial của rủi ro hoạt động và bảo hiểm,

mô phỏng được sử dụng để tính toán tổng mức tổn thất bằng cách kết hợp sự phụ thuộc giữa tần suất xuất hiện và mức độ nghiêm trọng của các loại tổn thất khác nhau.

III.1 Quy trình chung cho phân phối Meta

Phân phối Meta cung cấp giải pháp thuật toán tích hợp để liên kết cấu trúc của một hàm Copula C với các phân phối biên $F_1, \dots, F_d$ tùy ý. Về mặt thực hành tính toán, quy trình mô phỏng bao gồm hai bước nền tảng:

- Bước đầu tiên là phát sinh thành công một vectơ ngẫu nhiên biến đều tiêu chuẩn $U = (U_1, \dots, U_d)^T$ dựa trên thuật toán lấy mẫu của Copula C đã lựa chọn.
- Bước tiếp theo sử dụng phép biến đổi phân vị nghịch đảo bằng cách thiết lập giá trị thực tế $X_i = F_i^{-1}(U_i)$ với mọi $i = 1, \dots, d$.

Vectơ đầu ra $X = (X_1, \dots, X_d)^T$ được tạo thành đảm bảo phản ánh chuẩn xác các đặc tính biên mong muốn gắn liền với cấu trúc phụ thuộc gốc từ hệ hàm Copula đã chọn.

III.2 Mô phỏng Gauss Copula

Gauss Copula được trích xuất từ phân phối chuẩn đa biến. Thuật toán tuân thủ quy trình sau:

- Thực hiện phân rã Cholesky ma trận tương quan P để thu được nhân tử Cholesky $P^{1/2}$.
- Tạo vectơ $Z = (Z_1, \dots, Z_d)^T$ có phân phối chuẩn đa biến $N_d(0, P)$ bằng cách đặt $Z = P^{1/2}\epsilon$, với ϵ là vectơ các biến chuẩn tắc độc lập.
- Trả về vectơ kết quả cuối cùng $U = (\Phi(Z_1), \dots, \Phi(Z_d))^T$, trong đó Φ là hàm phân phối chuẩn tắc đơn biến.

III.3 Mô phỏng t Copula

Thuật toán này dựa trên việc mô phỏng phân phối Student t đa biến. Để tạo một vectơ $X \sim t_d(\nu, 0, P)$, quy trình tuân theo các bước cụ thể:

- Tạo vectơ $Z \sim N_d(0, P)$ như ở thuật toán Gauss.
- Tạo độc lập một biến trộn $W \sim Ig(\nu/2, \nu/2)$ thuộc phân phối nghịch đảo Gamma, hoặc tạo biến trộn từ phân phối khi bình phương thông qua hệ thức $\nu/W \sim \chi_\nu^2$.
- Tiến hành đặt $X = \sqrt{W}Z$.
- Trả về vectơ kết quả sau cùng $U = (t_\nu(X_1), \dots, t_\nu(X_d))^T$, trong đó t_ν là hàm phân phối Student t đơn biến với ν bậc tự do.

III.4 Mô phỏng Copula Archimedean (LT-Archimedean)

Phương pháp này sử dụng biến đổi Laplace-Stieltjes để tạo ra các Copula có tính trao đổi trong mọi số chiều. Quy trình thực hiện gồm các bước:

- Tạo một biến ngẫu nhiên V có hàm phân phối G sao cho biến đổi Laplace-Stieltjes $\hat{G}$ của nó chính là nghịch đảo của hàm sinh Copula $\phi = \hat{G}^{-1}$.
- Tạo các biến ngẫu nhiên đều tiêu chuẩn độc lập $X_1, \dots, X_d$.
- Trả về vectơ kết quả được tính theo biểu thức:

$$U = \left(\hat{G} \left(-\frac{\ln(X_1)}{V} \right), \dots, \hat{G} \left(-\frac{\ln(X_d)}{V} \right) \right)^T$$

Đối với các trường hợp cụ thể, cấu trúc của biến trộn V được xác định riêng biệt cho từng loại Copula:

- Với Clayton Copula: biến V được mô phỏng từ phân phối Gamma $\text{Ga}(1/\theta, 1)$.
- Với Gumbel Copula: biến V được mô phỏng từ phân phối ổn định dương.
- Với Frank Copula: V là biến ngẫu nhiên rời rạc có hàm khối xác suất được tính theo công thức $p(k) = (1 - e^{-\theta})^k / (k\theta)$.

III.5 Các thuật toán nâng cao cho phân phối hỗn hợp chuẩn

Đối với các cấu trúc nâng cao thuộc họ phân phối hỗn hợp chuẩn, quy trình mô phỏng đòi hỏi các kỹ thuật xử lý chuyên biệt:

- Khi mô phỏng Skewed t Copula, biến ngẫu nhiên được khởi tạo từ phân phối t lệch đa biến, sau đó các biến số U_i được tính toán thông qua tích phân số của mật độ t lệch đơn biến.
- Đối với Grouped t Copula, mô hình cho phép các nhóm biến có mức độ phụ thuộc khác nhau bằng cách sử dụng các biến trộn W_k khác nhau cho từng nhóm, nhưng vẫn đảm bảo các biến trộn này có tính đồng biến với nhau.

IV CÁC TIÊU CHÍ KIỂM ĐỊNH VÀ PHƯƠNG PHÁP NGHIÊN CỨU

IV.1 Thu thập và xử lý dữ liệu

- Dữ liệu sử dụng trong nghiên cứu này là chuỗi dữ liệu lịch sử giá đóng cửa hàng ngày của bốn cổ phiếu công nghệ bao gồm: Apple Inc. (*AAPL*), Microsoft Corp. (*MSFT*), Amazon.com Inc. (*AMZN*), và Alphabet Inc. (*GOOGL*). Dữ liệu được trích xuất từ tập dữ liệu `all_stocks_5yr.csv`, bao gồm các thông tin giao dịch lịch sử trong giai đoạn 5 năm từ ngày 08/02/2013 đến ngày 07/02/2018. Tổng số quan sát thu được là 1.259 ngày giao dịch cho mỗi cổ phiếu. Chuỗi giá đóng cửa này sau đó được xử lý bằng cách chuyển đổi sang tỷ suất sinh lợi logarit hàng ngày để phục vụ cho các bước kiểm định và mô hình hóa tiếp theo.

- Để loại bỏ xu hướng thời gian và đảm bảo tính dừng của chuỗi dữ liệu, giá đóng cửa của các cổ phiếu được chuyển đổi sang chuỗi tỷ suất sinh lợi logarit hàng ngày. Tỷ suất sinh lợi $R_{i,t}$ được xác định bằng công thức:

$$R_{i,t} = \ln \left(\frac{P_{i,t}}{P_{i,t-1}} \right) \quad (30)$$

Trong đó $P_{i,t}$ và $P_{i,t-1}$ lần lượt là giá đóng cửa của cổ phiếu i tại ngày giao dịch t và $t - 1$.

IV.2 Thống kê mô tả và Kiểm định dữ liệu đầu vào

IV.2.1 Hệ số bất đối xứng và hệ số nhọn

Trong nghiên cứu tài chính hiện đại, việc giả định chuỗi tỷ suất sinh lợi tuân theo phân phối chuẩn đối xứng thường xuyên bị thách thức bởi các biến động thực tế trên thị trường. Sau khi thiết lập quy trình mô phỏng các kịch bản, việc đánh giá hình dáng phân phối xác suất của các tài sản đóng vai trò quyết định, trong đó hai đại lượng thống kê mô tả cốt lõi được sử dụng là hệ số bất đối xứng và hệ số nhọn.

Hệ số bất đối xứng, ký hiệu là S , đo lường mức độ lệch của phân phối xác suất so với hình dáng đối xứng hoàn hảo của phân phối chuẩn qua công thức toán học:

$$S = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] \quad (31)$$

Khi hệ số này bằng không, phân phối đạt trạng thái đối xứng lý tưởng. Ngược lại, một chuỗi tỷ suất sinh lợi có hệ số bất đối xứng âm sẽ có phần đuôi bên trái dài hơn, hàm ý rằng các biến cố sụt giảm mạnh mang tính chất cực đoan xuất hiện với tần suất cao. Trong khi đó, hệ số bất đối xứng dương lại thể hiện phân phối lệch phải, nơi các cơ hội tăng trưởng đột biến chiếm ưu thế trên thị trường.

Để ước lượng giá trị này từ tập dữ liệu thực tế, hệ số bất đối xứng mẫu (b) được xác định bởi công thức:

$$b = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3}{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^{3/2}} \quad (32)$$

Bên cạnh độ lệch, hệ số nhọn, ký hiệu là K , đóng vai trò quan trọng trong việc xác định độ tập trung của đỉnh phân phối và độ dày của hai vùng đuôi đối với cả dữ liệu thực tế lẫn dữ liệu sau khi mô phỏng. Đại lượng này được xác định bằng biểu thức:

$$K = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] \quad (33)$$

Để tính toán từ dữ liệu thực tế, hệ số nhọn mẫu, ký hiệu là k , được xác định bởi công thức:

$$k = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^4}{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^2} \quad (34)$$

Đối với một phân phối chuẩn lý thuyết, giá trị của hệ số nhọn luôn cố định bằng ba. Nhằm thuận tiện cho việc so sánh, các nhà nghiên cứu thường sử dụng khái niệm hệ số nhọn dư, được tính bằng cách lấy hệ số nhọn tổng trừ đi ba. Đối với các chuỗi số liệu tài

chính, hệ số nhọn dư thường lớn hơn không, tạo nên hiện tượng phân phối có đỉnh nhọn và đuôi nặng. Đặc tính này cảnh báo rằng xác suất xảy ra các cú sốc lớn trên thị trường cao hơn rất nhiều so với những gì mô hình phân phối chuẩn dự báo. Do đó, việc đo lường hai đại lượng này giúp kiểm chứng xem cấu trúc dữ liệu sinh ra từ thuật toán mô phỏng Monte Carlo dựa trên Copula ở chương trước có tái lập thành công hiện tượng đuôi nặng này hay không.

IV.2.2 Kiểm định tính chuẩn Jarque-Bera (JB)

Kiểm định Jarque-Bera được thiết lập như một công cụ kiểm tra giả thuyết số học chính thức thuộc nhóm các kiểm định mô-men tổng quát. Bản chất của phương pháp này là đánh giá đồng thời liệu hệ số bất đối xứng và hệ số nhọn của dữ liệu có nhất quán với các đặc tính lý thuyết của mô hình phân phối chuẩn Gaussian hay không. Trong không gian lý thuyết, một phân phối chuẩn hoàn hảo luôn sở hữu hệ số bất đối xứng bằng không và hệ số nhọn bằng ba. Thống kê kiểm định Jarque-Bera, ký hiệu là T , được cấu trúc dựa trên cỡ mẫu n phối hợp cùng hai hệ số hình dáng đã được xác định thông qua công thức tổng quát:

$$T = \frac{n}{6} \left(b^2 + \frac{1}{4}(k - 3)^2 \right) \quad (35)$$

Dưới giả thuyết không (H_0) cho rằng dữ liệu tuân theo phân phối chuẩn, đại lượng thống kê T sẽ có phân phối Chi-bình phương (χ^2) tiệm cận với hai bậc tự do.

Quy tắc quyết định:

- Bác bỏ tính chuẩn: Nếu giá trị hệ số nhọn mẫu khác biệt lớn so với 3 hoặc hệ số bất đối xứng mẫu khác biệt lớn so với 0, giá trị T sẽ tăng cao, dẫn đến việc bác bỏ giả thuyết về phân phối chuẩn.
- Giá trị p (p-value): Thông thường, nếu p-value nhỏ hơn ngưỡng ý nghĩa (ví dụ: 0.05), giả thuyết không sẽ bị bác bỏ

IV.3 Phương pháp ước lượng và kiểm định hàm Copula

IV.3.1 Phương pháp ước lượng hàm Copula

Để cấu trúc mô hình phân phối đa biến từ các dữ liệu thực tế, nghiên cứu áp dụng phương pháp Hàm suy diễn cho các biên (Inference Functions for Margins - IFM). Đây là một kỹ thuật ước lượng hợp lý cực đại (Maximum Likelihood Estimation - MLE) theo hai giai đoạn, giúp giảm thiểu độ phức tạp tính toán so với việc ước lượng đồng thời toàn bộ tham số.

- Giai đoạn 1 (Ước lượng biên): Sử dụng hàm phân phối tích lũy thực nghiệm (ECDF) để chuyển đổi chuỗi tỷ suất sinh lợi gốc của từng tài sản thành các chuỗi quan sát giả đồng nhất trên không gian $U[0, 1]$. Việc sử dụng ECDF giúp bảo toàn tuyệt đối các đặc tính bất đối xứng và phân phối đuôi nặng của dữ liệu thực tế mà không cần áp đặt bất kỳ giả định tham số nào lên phân phối biên.
- Giai đoạn 2 (Ước lượng tham số Copula): Dựa trên các dữ liệu đã được chuẩn hóa ở miền $U[0, 1]$, tiến hành tối đa hóa hàm logarit của hàm hợp lý để tìm ra bộ tham số tối ưu cho từng hàm Copula ứng viên (ví dụ: ma trận tương quan và bậc tự do đối với t-Student Copula).

Sau khi ước lượng, tiêu chuẩn Cramér-von Mises dựa trên Copula thực nghiệm sẽ được sử dụng để kiểm định độ khớp mô hình (Goodness-of-Fit), từ đó chọn ra cấu trúc phụ thuộc mô tả chính xác nhất hành vi dữ liệu.

IV.3.2 Kiểm định độ phù hợp Cramér-von Mises (sử dụng chỉ số MSE)

Việc lựa chọn một hàm Copula phù hợp với cấu trúc phụ thuộc của dữ liệu thực nghiệm là một bước mang tính quyết định trong mô hình hóa rủi ro. Để đánh giá và xếp hạng độ khớp của các mô hình Copula lý thuyết (Gaussian, t-Student, Clayton), nghiên cứu sử dụng tiêu chuẩn khoảng cách Cramér-von Mises.

Bản chất của tiêu chuẩn này là cực tiểu hóa sai số toàn phương trung bình (Mean Squared Error - MSE) giữa hàm phân phối Copula thực nghiệm trích xuất từ dữ liệu và hàm Copula lý thuyết. Gọi $C_n(\mathbf{u})$ là hàm Copula thực nghiệm và $C_\theta(\mathbf{u})$ là hàm Copula lý thuyết với bộ tham số θ , đại lượng thống kê Cramér-von Mises S_n được định nghĩa bằng công thức:

$$S_n = \sum_{i=1}^n (C_n(\mathbf{u}_i) - C_\theta(\mathbf{u}_i))^2 \quad (36)$$

Trong đó:

- n : Kích thước mẫu (số lượng quan sát thực nghiệm).
- $\mathbf{u}_i$: Vector các quan sát giả (pseudo-observations) trên không gian đồng nhất $[0, 1]^d$.
- $C_n(\mathbf{u}_i)$: Tần suất tích lũy thực nghiệm tại điểm $\mathbf{u}_i$.
- $C_\theta(\mathbf{u}_i)$: Giá trị tích lũy dự báo từ mô hình Copula lý thuyết tại điểm $\mathbf{u}_i$.

Mô hình Copula nào tạo ra giá trị thống kê S_n (hay mức sai số bình phương) nhỏ nhất sẽ được đánh giá là mô hình phản ánh sát nhất với cấu trúc phụ thuộc thực tế của danh mục đầu tư, từ đó được lựa chọn làm hàm lõi cho quá trình mô phỏng Monte Carlo.

IV.4 Quy trình mô phỏng Monte Carlo và tối ưu hóa danh mục đầu tư

Phương pháp luận của bài toán tối ưu hóa rủi ro được thiết kế theo một chu trình khép kín bao gồm các bước:

- Mô phỏng cấu trúc phụ thuộc: Từ hàm Copula đã được chọn ở bước kiểm định, tiến hành sinh ngẫu nhiên một tập mẫu lớn (10.000 kịch bản) các vector đa biến trên không gian đồng nhất. Tập mẫu này chứa đựng cấu trúc tương quan phi tuyến và các đặc tính phụ thuộc đuôi.
- Tái tạo kịch bản thị trường: Áp dụng phép biến đổi phân vị nghịch đảo thông qua ECDF để ánh xạ các vector đồng nhất về lại miền giá trị tỷ suất sinh lợi thực tế. Kết quả thu được là hàng ngàn kịch bản biến động giá khả dĩ của các tài sản.
- Giải bài toán tối ưu hóa: Thiết lập hàm mục tiêu cực tiểu hóa rủi ro đuôi $CVaR$ tại mức ý nghĩa $\alpha = 95\%$ thay vì cực tiểu hóa phương sai. Thuật toán tối ưu hóa phi tuyến tuần tự (SLSQP) được áp dụng để tìm kiếm bộ tỷ trọng phân bổ vốn $(w_1, w_2, \dots, w_n)$ thỏa mãn các ràng buộc về ngân sách ($\sum w_i = 1$) và không bán khống ($w_i \geq 0$).

IV.5 Quy trình phân tích dữ liệu

Để giải quyết bài toán tối ưu hóa danh mục đầu tư và đánh giá rủi ro, quy trình phân tích dữ liệu trong nghiên cứu được cấu trúc thành các bước tuần tự như sau:

Bước 1: Phân tích thống kê mô tả đơn biến

Chuỗi tỷ suất sinh lợi của từng cổ phiếu được kiểm tra các đặc tính phân phối thống kê cơ bản thông qua các chỉ số: trung bình, độ lệch chuẩn, độ lệch và độ nhọn. Đặc biệt, hệ số nhọn được tính toán để xác nhận tính chất đuôi nặng và đỉnh nhọn. Đây là một trong những hiện tượng phổ biến thường thấy trong chuỗi thời gian tài chính, làm cơ sở vững chắc cho việc áp dụng hàm Copula thay vì dựa vào giả định phân phối chuẩn truyền thống.

Bước 2: Phân tích cấu trúc phụ thuộc

Để đo lường sự phụ thuộc phi tuyến giữa các cổ phiếu, nghiên cứu sử dụng ma trận tương quan hạng Spearman thay vì tương quan Pearson thông thường. Sự phụ thuộc ở phần đuôi phân phối (khi thị trường xảy ra biến động mạnh) cũng được đánh giá qua hệ số tương quan đuôi thực nghiệm tại các mức phân vị cực trị nhằm dự báo nguy cơ hội tụ rủi ro.

Bước 3: Tối ưu hóa danh mục theo mô hình Markowitz

Dựa trên ma trận hiệp phương sai và lợi nhuận kỳ vọng của các tài sản, thuật toán SLSQP (Sequential Least Squares Programming) được sử dụng để giải bài toán tối ưu hóa có ràng buộc. Mục tiêu là tìm ra bộ tỷ trọng phân bổ vốn (w_1, w_2, w_3, w_4) sao cho tỷ số Sharpe đạt giá trị cực đại. Các ràng buộc bao gồm: không bán khống ($w_i \geq 0$) và tổng tỷ trọng các tài sản bằng 100% ($\sum w_i = 1$).

Bước 4: Ước lượng Copula và mô phỏng Monte Carlo

Dựa vào bộ tỷ trọng tối ưu tìm được, nghiên cứu triển khai mô phỏng Monte Carlo với 10.000 kịch bản ngẫu nhiên. Quá trình này bao gồm:

- Sinh ma trận số ngẫu nhiên từ phân phối chuẩn đa biến dựa trên ma trận tương quan hạng Spearman.
- Chuyển đổi các giá trị ngẫu nhiên này sang phân phối đồng nhất $U[0, 1]$ bằng hàm phân phối tích lũy chuẩn.
- Sử dụng phép nghịch đảo phân vị thực nghiệm của chuỗi dữ liệu gốc để khôi phục lại các đặc tính phân phối thực tế của từng tài sản (nhằm tôn trọng tuyệt đối đặc tính đuôi nặng của dữ liệu lịch sử).
- Tổng hợp tỷ suất sinh lợi danh mục cho 10.000 kịch bản và tính toán chỉ số Giá trị rủi ro ($Var_{95\%}$) nhằm định lượng kịch bản tổn thất cực đoan nhất có thể xảy ra.

V PHÂN TÍCH MÔ PHỎNG VÀ KẾT QUẢ

V.1 Phân tích đơn biến

Phân tích thống kê mô tả đơn biến và kiểm định phân phối là bước đầu tiên nhằm nhận diện các đặc tính của chuỗi tỷ suất sinh lợi. Bảng dưới đây trình bày các giá trị thống kê cơ bản cùng kết quả kiểm định Jarque-Bera của 4 cổ phiếu công nghệ trong danh mục.

Bảng 1: Thống kê mô tả đơn biến của các tài sản

Chỉ số	AAPL	MSFT	AMZN	GOOGL
Trung bình (%)	0.0786	0.1039	0.1508	0.0880
Độ lệch chuẩn (%)	1.4587	1.4205	1.8228	1.3874
Độ lệch	0.0118	0.0539	0.7068	1.9527
Độ nhọn	3.7649	10.6883	11.9684	23.1649

Nhận xét: Kết quả từ Bảng 1 cho thấy tỷ suất sinh lợi trung bình hàng ngày của các cổ phiếu dao động từ 0.0786% đến 0.1508%, đi kèm với rủi ro (độ lệch chuẩn) tương ứng. Điểm đáng chú ý nhất là hệ số nhọn của cả 4 mã đều lớn hơn 0. Điều này cung cấp bằng chứng thực nghiệm mạnh mẽ về hiện tượng đuôi nặng và đỉnh nhọn - một trong những đặc trưng kinh điển của dữ liệu tài chính. Sự tồn tại của đuôi nặng cho thấy các biến cố cực đoan xảy ra với tần suất cao hơn đáng kể so với giả định của phân phối chuẩn, qua đó khẳng định việc sử dụng mô hình Copula trong các bước tiếp theo là cần thiết.

V.2 Phân tích biến phụ thuộc

Để đánh giá cấu trúc phụ thuộc giữa các tài sản, nghiên cứu tiến hành trích xuất cả tương quan tuyến tính (Pearson) và tương quan hạng phi tuyến (Spearman), đồng thời đo lường sự hội tụ ở vùng rủi ro cực đoan.

Bảng 2: Ma trận tương quan tuyến tính (Pearson)

	AAPL	AMZN	GOOGL	MSFT
AAPL	1.0000	0.2877	0.3489	0.3666
AMZN	0.2877	1.0000	0.5484	0.4027
GOOGL	0.3489	0.5484	1.0000	0.4884
MSFT	0.3666	0.4027	0.4884	1.0000

Bảng 3: Ma trận tương quan hạng Spearman

	AAPL	AMZN	GOOGL	MSFT
AAPL	1.0000	0.3385	0.3872	0.3720
AMZN	0.3385	1.0000	0.6338	0.4352
GOOGL	0.3872	0.6338	1.0000	0.5177
MSFT	0.3720	0.4352	0.5177	1.0000

Bảng 4: Ma trận tương quan đuôi dưới thực nghiệm (Phân vị 5%)


	AAPL	MSFT	AMZN	GOOGL
AAPL	1.0000	0.3498	0.3021	0.3498
MSFT	0.3498	1.0000	0.3339	0.4610
AMZN	0.3021	0.3339	1.0000	0.5246
GOOGL	0.3498	0.4610	0.5246	1.0000

Nhận xét

- Đối chiếu giữa Bảng 2 và Bảng 3, các hệ số tương quan hạng Spearman nhìn chung đều có giá trị lớn hơn hệ số tương quan tuyến tính Pearson. Điển hình ở cặp tài sản AMZN - GOOGL: mức độ tương quan Pearson chỉ là 0.5484, trong khi hệ số Spearman ghi nhận mức đồng biến lên tới 0.6338. Sự chênh lệch này là minh chứng rõ ràng cho thấy cấu trúc phụ thuộc giữa các cổ phiếu công nghệ mang tính phi tuyến. Tương quan Pearson đã đánh giá thấp mối liên kết này do bị nhiễu bởi các giá trị ngoại lai, trong khi Spearman phản ánh trung thực hơn sự đồng biến cấu trúc của thị trường.
- Giới hạn của các hệ số tương quan tổng thể (Pearson hay Spearman) là chúng chỉ phản ánh trạng thái bình quân của thị trường. Khi quan sát hệ số tương quan đuôi dưới thực nghiệm tại mức phân vị 5% cực đoan nhất (Bảng 4), kết quả ghi nhận sự đồng biến rất lớn. Đặc biệt với cặp AMZN và GOOGL, mức độ cùng sụt giảm chạm ngưỡng 0.5246. Cặp MSFT và GOOGL cũng ghi nhận mức tương quan đuôi cao 0.4610.
- Dữ liệu từ Bảng 4 mang lại một thông điệp cảnh báo nghiêm trọng: Khi thị trường hoảng loạn, xác suất các cổ phiếu này cùng lao dốc là cực kỳ cao. Cơ chế hội tụ rủi ro hệ thống này sẽ phá vỡ hoàn toàn hàng rào bảo vệ của chiến lược đa dạng hóa truyền thống Markowitz (vốn giả định rủi ro phân phối chuẩn và độc lập tiệm cận). Điều này đòi hỏi nghiên cứu phải khẩn trương chuyển sang sử dụng mô hình Copula ở các bước tiếp theo nhằm định lượng chính xác mức độ thiệt hại trong kịch bản các tài sản cùng sụp đổ đồng thời.

V.3 Tối ưu hóa danh mục đầu tư

Trước khi áp dụng mô hình Copula, bài toán tối ưu hóa Mean-Variance (Markowitz) được giải quyết bằng thuật toán SLSQP nhằm tìm ra danh mục tiếp điểm có tỷ số Sharpe cực đại nhằm tìm ra danh mục có mức bù rủi ro tốt nhất. Hình 1 và Bảng 5 trình bày kết quả tỷ trọng phân bổ vốn và các chỉ số hiệu suất của danh mục tối ưu này.



Hình 1: Đường biên hiệu quả Markowitz và Đường thị trường vốn (CML)

Bảng 5: Kết quả tối ưu hóa danh mục theo mô hình Markowitz

Chỉ số / Tài sản	Kết quả tối ưu
Tỷ số Sharpe lớn nhất	1.5172
Lợi nhuận kỳ vọng (Năm)	29.66%
Rủi ro danh mục / Độ lệch chuẩn (Năm)	19.55%
Tỷ trọng phân bổ tối ưu	
Cổ phiếu AAPL	18.45%
Cổ phiếu MSFT	40.96%
Cổ phiếu AMZN	4.60%
Cổ phiếu GOOGL	35.99%

Nhận xét từ Bảng 5 và Hình 1:

- Kết quả từ thuật toán tối ưu hóa SLSQP cho thấy sự phân hóa rõ rệt trong việc lựa chọn tài sản. Dòng vốn được ưu tiên tập trung phần lớn vào MSFT (40.96%) và GOOGL (35.99%), trong khi AMZN bị thu hẹp đáng kể chỉ còn 4.60%. Cấu trúc này hoàn toàn nhất quán với những phát hiện từ phân tích đơn biến, AMZN là tài sản có độ lệch chuẩn cao nhất (1.8228%/ngày), do đó thuật toán Markowitz tự động tránh cổ phiếu này để giảm thiểu sự gia tăng của phương sai tổng, nhằm đạt được tỷ số Sharpe tối đa.
- Danh mục tối ưu đạt được tỷ số Sharpe lớn nhất là 1.5172, mang lại mức lợi nhuận kỳ vọng 29.66%/năm với mức rủi ro hệ thống (độ lệch chuẩn) là 19.55%/năm. Quan sát trên đồ thị Hình 1, danh mục này (ngôi sao màu đỏ) chính là tiếp điểm tiếp tuyến hoàn hảo giữa đường thị trường vốn (CML - màu tím) và Đường biên hiệu quả Markowitz. Đây là ranh giới hiệu quả cao nhất mà một nhà đầu tư có thể đạt được trong giới hạn lý thuyết tài chính truyền thống.

- Mặc dù mang lại một bức tranh lợi nhuận - rủi ro có vẻ hoàn hảo, nhưng con số rủi ro 19.55%/năm này có một hạn chế lớn. Phương sai trong mô hình Markowitz giả định rủi ro tuân theo phân phối chuẩn và mang tính đối xứng. Tuy nhiên, các kiểm định trên đã chứng minh chuỗi dữ liệu có hiện tượng đuôi nặng và sự hội tụ rủi ro phi tuyến. Nghĩa là con số rủi ro 19.55% này đang đánh giá thấp đi rất nhiều mức độ tổn thất của các cú sốc cực đoan. Nếu thị trường xảy ra khủng hoảng đồng loạt, hệ số tương quan tuyến tính sẽ bị phá vỡ, và danh mục Markowitz này hoàn toàn không có khả năng chống đỡ.

Chính vì khiếm khuyết cơ bản này, việc đo lường lại rủi ro danh mục bằng giá trị VaR/CVaR thông qua mô phỏng Copula ở các bước tiếp theo là yêu cầu mang tính bắt buộc để phản ánh đúng biến động thực tế của thị trường tài chính.

V.4 Áp dụng mô hình Copula

Dựa trên những bằng chứng về sự tồn tại của cấu trúc phụ thuộc phi tuyến và hiện tượng hội tụ rủi ro cực đoan ở trên, nghiên cứu tiến hành khớp dữ liệu thực nghiệm vào ba mô hình Copula tiêu biểu: Gaussian Copula (đại diện cho phân phối chuẩn, không có phụ thuộc đuôi), t-Student Copula (đại diện cho phụ thuộc đuôi đối xứng) và Clayton Copula (đại diện cho phụ thuộc đuôi dưới bất đối xứng).

Để xác định mô hình phản ánh sát nhất với thực tế thị trường, nghiên cứu sử dụng tiêu chuẩn khoảng cách Cramér-von Mises. Cụ thể, thuật toán tiến hành tính toán tổng bình phương sai số (MSE) giữa hàm Copula thực nghiệm và các hàm Copula lý thuyết được mô phỏng với kích thước mẫu 10.000 kịch bản. Mô hình có giá trị MSE nhỏ nhất sẽ được lựa chọn.

Bảng 6: Kết quả kiểm định độ phù hợp dựa trên sai số bình phương trung bình

Mô hình Copula	Sai số toàn phương trung bình (MSE)	Xếp hạng
Gaussian Copula	0.1452	2
t-Student Copula (df=4)	0.0891	1
Clayton Copula	0.2105	3

Nhận xét từ Bảng 6:

- Kết quả đo lường chỉ ra rằng t-Student Copula có mức sai số thấp nhất (0.0891), vượt trội hơn hẳn so với Gaussian Copula (0.1452) và Clayton Copula (0.2105). Kết quả này hoàn toàn nhất quán với những phát hiện từ phân tích tương quan đuôi trước đó: cấu trúc phụ thuộc của các cổ phiếu công nghệ không tuân theo phân phối chuẩn, mà có đặc tính đuôi nặng và mức độ đồng biến cao trong các trạng thái thị trường cực đoan.
- Việc mô hình Gaussian Copula có sai số lớn và cho thấy sự hạn chế đáng kể trong quá trình mô hình hóa, đồng thời khẳng định giới hạn của các phương pháp đo lường tuyến tính truyền thống. Trong khi đó, Clayton Copula (vốn chỉ nhạy bén với cấu trúc đuôi dưới) cũng không đạt được độ khớp tối ưu, cho thấy tính chất phụ thuộc của nhóm tài sản này mang xu hướng đối xứng hơn ở cả hai vùng cực đoan.

- Từ cơ sở thực nghiệm vững chắc này, t-Student Copula được lựa chọn làm mô hình nền tảng. Hàm Copula này sẽ đóng vai trò là lõi cấu trúc phụ thuộc cho thuật toán mô phỏng Monte Carlo ở bước tiếp theo, phản ánh sát với đặc tính biến động thực tế của thị trường tài chính.


V.5 Mô hình mô phỏng Monte Carlo và tối ưu hóa rủi ro

V.5.1 Phân tích mô phỏng Monte Carlo với 10.000 kịch bản

Dựa trên kết quả lựa chọn mô hình ở trên, bài toán quản trị rủi ro được triển khai thông qua hai pha kỹ thuật chính là: Mô phỏng các kịch bản thị trường bằng phương pháp Monte Carlo và tối ưu hóa tỷ trọng phân bổ vốn nhằm kiểm soát rủi ro cực đoan.

Mục tiêu của bước này là tạo ra một tập dữ liệu đủ lớn, phản ánh toàn diện các trạng thái biến động của thị trường, đặc biệt là các cú sốc giảm giá đồng loạt. Quy trình mô phỏng được thực hiện như sau:

- Khởi tạo kịch bản từ hàm Copula: Thuật toán sinh ra 10.000 vector quan sát đồng nhất từ hàm t-Student Copula với bậc tự do $df = 4$. Ma trận này chứa đựng trọn vẹn đặc tính đuôi nặng và cấu trúc tương quan phi tuyến giữa 4 cổ phiếu công nghệ.
- Khôi phục phân phối biên bằng ECDF: Để đảm bảo các kịch bản lợi suất không bị ép vào khuôn khổ phân phối chuẩn, nghiên cứu sử dụng hàm phân phối tích lũy thực nghiệm (Empirical CDF - ECDF). Các giá trị đồng nhất được ánh xạ ngược (F^{-1}) về thang đo tỷ suất sinh lợi thực nghiệm, giúp giữ nguyên vẹn độ lệch và độ nhọn của dữ liệu thực nghiệm.




Hình 2: Phân phối tỷ suất sinh lợi hàng ngày của danh mục từ mô phỏng Copula

Quan sát Hình 2, phân phối lợi suất hàng ngày thể hiện rõ đặc tính nặng đuôi. Đối với danh mục phân bổ đều ban đầu, ngưỡng rủi ro VaR 95% được xác định ở mức -1.56%, nghĩa là trong điều kiện thị trường bình thường, xác suất danh mục giảm sâu hơn mức

này chỉ giới hạn ở 5%. Đây là cơ sở dữ liệu nền tảng để tiến hành tối ưu hóa CVaR ở bước tiếp theo.

V.5.2 Chiến lược tối ưu hóa danh mục theo rủi ro đuôi (CVaR)

Thay vì chỉ kiểm soát phương sai như phương pháp Markowitz truyền thống, nghiên cứu thiết lập bài toán tối ưu hóa phi tuyến (SLSQP) trên 10.000 kịch bản vừa tạo ra. Mục tiêu cốt lõi là cực tiểu hóa rủi ro đuôi, đại diện bởi chỉ số Giá trị chịu rủi ro có điều kiện (CVaR) tại mức ý nghĩa $\alpha = 95\%$.



Hình 3: Phân phối lợi suất của danh mục tối ưu t-Student Copula và các ngưỡng rủi ro


Nhận xét:

- Quan sát Hình 3, hai đường ranh giới quan trọng được xác định bao gồm VaR (màu đỏ) đại diện cho ngưỡng tổn thất tối đa ở điều kiện bình thường và CVaR (màu cam) đại diện cho thiệt hại trung bình khi thị trường rơi vào trạng thái cực đoan.
- Việc áp dụng thuật toán tối ưu hóa CVaR đã giúp thu hẹp đáng kể rủi ro của danh mục. Cụ thể, ngưỡng tổn thất tối đa (VaR 95%) đã được cải thiện tích cực từ mức -1.56% (trước tối ưu ở Hình 2) xuống chỉ còn -1.47% (sau tối ưu ở Hình 3).
- Sự chênh lệch này minh chứng rõ nét cho hiệu quả thực chứng của thuật toán trong việc cấu trúc lại tỷ trọng tài sản. So với danh mục Markowitz truyền thống vốn dễ vỡ trước các đợt bán tháo đồng loạt, danh mục Copula-CVaR đã chủ động thiết lập một lớp phòng vệ an toàn và tối ưu hơn hẳn cho nhà đầu tư.

V.6 Dự báo hiệu suất danh mục tối ưu trong dài hạn (1 năm)


Để đánh giá tính thực tiễn của cấu trúc danh mục đã được tối ưu hóa bằng t-Student Copula, nghiên cứu tiến hành mô phỏng quỹ đạo tài sản (Asset Paths) trong chu kỳ 1

năm (tương đương 252 ngày giao dịch) dựa trên 10.000 kịch bản Monte Carlo. Giả định giá trị vốn gốc ban đầu được chuẩn hóa là 1.0.



Hình 4: Mô phỏng Monte Carlo 10.000 kịch bản quỹ đạo tài sản tích lũy trong 1 năm

Hình 4 minh họa quá trình tiến hóa của giá trị danh mục qua thời gian. Mặc dù có sự phân tán rộng do tính biến động tự nhiên của các cổ phiếu công nghệ, xu hướng chung của đám mây điểm cho thấy sự tăng trưởng tích cực, phần lớn các quỹ đạo đều nằm trên mức vốn gốc ban đầu (đường gạch đứt màu đỏ). Để lượng hóa chính xác hơn rủi ro và lợi nhuận tại thời điểm đáo hạn (ngày giao dịch thứ 252), phân phối giá trị tài sản cuối kỳ được trình bày tại Hình 5.



Hình 5: Phân phối giá trị tài sản tích lũy của danh mục vào cuối năm

Nhận xét kết quả kiểm chứng:

- Khả năng sinh lời: Giá trị tài sản trung vị cuối năm đạt 1.25, đồng nghĩa với việc nhà đầu tư có thể kỳ vọng mức tăng trưởng tài sản xấp xỉ 25% sau 1 năm nắm giữ danh mục tối ưu này.
- Năng lực phòng thủ rủi ro: Chỉ số rủi ro ròng tại phân vị 5% cho thấy giá trị tài sản chặn dưới là 0.95. Điều này có ý nghĩa kinh tế rất lớn: Nếu đầu tư 1 đồng, ngay cả khi thị trường rơi vào kịch bản xấu (thuộc nhóm 5% tồi tệ nhất), nhà đầu tư vẫn bảo toàn được ít nhất 0.95 đồng (chỉ lỗ tối đa khoảng 5% vốn gốc trong 1 năm).

Kết quả này một lần nữa khẳng định sức mạnh của việc kết hợp mô hình Copula và tiêu chuẩn tối ưu hóa CVaR: danh mục không chỉ khai thác được mức tăng trưởng mạnh mẽ của nhóm cổ phiếu công nghệ mà còn thiết lập được một cơ chế phòng vệ vững chắc chống lại rủi ro hệ thống.

VI Ý NGHĨA PHƯƠNG PHÁP QUẢN TRỊ

VI.1 Giải thích kết quả

Kết quả từ mô hình tối ưu hóa Copula-CVaR cho thấy một sự dịch chuyển quan trọng trong việc tiếp cận quản trị rủi ro: sự an toàn của danh mục không đến từ việc loại bỏ hoàn toàn biến động, mà đến từ việc kiểm soát những tổn thất cực đoan nhất. Bằng cách ghi nhận hiện tượng đuôi nặng và sự phụ thuộc phi tuyến, mô hình đã thành công trong việc nhận diện những khiếm khuyết của phương pháp Markowitz truyền thống. Việc ngưỡng rủi ro VaR được ép xuống mức thấp hơn chứng minh rằng, khi thuật toán nhận thức được xác suất xảy ra các đợt bán tháo đồng loạt, nó sẽ tự động cơ cấu lại tỷ trọng để tạo ra một danh mục có sức đề kháng mạnh mẽ hơn trước các cú sốc hệ thống.

VI.2 Ý nghĩa cho doanh nghiệp

Đối với các quỹ đầu tư và tổ chức tài chính, việc ứng dụng mô hình này mang lại những công cụ phòng vệ mang tính thực tiễn cao:

- Thiết lập hạn mức rủi ro (Risk Limits) chính xác hơn: Thay vì dựa vào giả định phân phối chuẩn dễ dẫn đến việc cấp vốn quá tay cho các tài sản tiềm ẩn rủi ro sụp đổ, các tổ chức có thể dùng $CVaR$ dựa trên Copula để tính toán chính xác mức vốn kinh tế (Economic Capital) cần dự trữ.
- Kiểm tra sức chịu đựng (Stress Testing): Việc linh hoạt thay đổi các tham số trong mô phỏng Copula cho phép các nhà quản trị tạo ra các kịch bản khủng hoảng cộng hưởng để kiểm tra sức chống chịu của danh mục, từ đó có các biện pháp phòng vệ kịp thời.

VI.3 Ý nghĩa cho nghiên cứu học thuật

Nghiên cứu này làm cầu nối giữa lý thuyết thống kê bậc cao và thực tiễn thị trường tài chính. Việc bác bỏ Gaussian Copula để chọn t-Student Copula đã cung cấp thêm bằng chứng thực nghiệm vững chắc về sự tồn tại của cấu trúc phụ thuộc đuôi trong nhóm cổ

phiếu công nghệ. Đồng thời, nghiên cứu minh họa trực quan sự ưu việt của phân phối Meta (kết hợp Copula và ECDF) trong việc giải quyết bài toán đa biến phi tuyến, mở ra hướng tiếp cận linh hoạt hơn so với việc cố gắng khớp dữ liệu vào các phân phối chuẩn đa biến cứng nhắc.

VII KẾT LUẬN VÀ HƯỚNG NGHIÊN CỨU TƯƠNG LAI

VII.1 Tóm tắt kết quả chính

Khóa luận đã tiếp cận và giải quyết thành công bài toán tối ưu hóa danh mục đầu tư trong điều kiện thị trường tồn tại các rủi ro cực đoan. Thay vì dựa vào lý thuyết Markowitz với điểm yếu chí mạng là giả định phân phối chuẩn và tương quan tuyến tính, nghiên cứu đã tiên phong ứng dụng lý thuyết Copula để bóc tách và mô hình hóa chính xác cấu trúc phụ thuộc của 4 cổ phiếu công nghệ hàng đầu (AAPL, MSFT, AMZN, GOOGL).

Kết quả thực nghiệm chỉ ra rằng, chuỗi tỷ suất sinh lợi của các tài sản này có đặc tính đuôi nặng và mức độ đồng biến rất cao trong các trạng thái thị trường cực đoan. Hàm t-Student Copula đã chứng minh sự vượt trội khi nắm bắt thành công đặc tính này. Thông qua thuật toán mô phỏng Monte Carlo với 10.000 kịch bản, kết hợp cùng kỹ thuật cực tiểu hóa $CVaR$, nghiên cứu đã thiết lập được một cơ cấu tỷ trọng tối ưu mới. Danh mục này không chỉ duy trì được tiềm năng sinh lời mà còn thu hẹp đáng kể ngưỡng rủi ro tổn thất tối đa ($VaR_{95\%}$ giảm từ 1.56% xuống 1.47%), tạo ra một lớp phòng vệ vững chắc bảo vệ vốn đầu tư trước các đợt đứt gãy của thị trường.

Về mặt học thuật, kết quả này đóng góp một minh chứng định lượng rõ nét, phản bác lại sự phụ thuộc quá mức vào hệ số tương quan Pearson trong các giáo trình tài chính truyền thống, đồng thời khẳng định tính ứng dụng của Copula trong môi trường đầu tư thực tế.

VII.2 Hướng nghiên cứu trong tương lai

Mặc dù đã đạt được những kết quả khả quan, mô hình vẫn có thể được mở rộng và phát triển ở các khía cạnh sau:

- Mở rộng quy mô và loại hình tài sản: Nghiên cứu trong tương lai có thể áp dụng mô hình cho các danh mục đa dạng hơn, bao gồm sự kết hợp giữa các lớp tài sản khác nhau (cổ phiếu, trái phiếu, tiền điện tử, hàng hóa) để kiểm chứng hiệu quả đa dạng hóa xuyên thị trường.
- Áp dụng các Copula động: Mô hình hiện tại sử dụng Copula tĩnh, trong khi thực tế cấu trúc phụ thuộc có thể thay đổi theo thời gian. Các nghiên cứu tiếp theo có thể tích hợp mô hình Copula biến thiên theo thời gian (ví dụ: DCC-Copula) để phản ánh sự chuyển pha của thị trường linh hoạt hơn.
- Tích hợp Học máy (Machine Learning): Có thể kết hợp các thuật toán học sâu để dự báo các tham số của hàm phân phối biên hoặc tối ưu hóa tốc độ hội tụ của thuật toán SLSQP khi giải quyết bài toán danh mục có kích thước lớn.

Tài liệu tham khảo

- [1] Argimiro Arratia. *Computational Finance: An Introductory Course with R*. Vol. 1. Atlantis Studies in Computational Finance and Financial Engineering. Paris, France: Atlantis Press, 2014. ISBN: 978-94-6239-069-0. DOI: 10.2991/978-94-6239-070-6.
- [2] Đặng Đức Trọng, Đinh Ngọc Thanh, and Phạm Hoàng Uyên. *Xác suất và Thống kê*. Tái bản mới nhất. TP.HCM, Việt Nam: Nhà xuất bản Đại học Quốc gia TP.HCM, 2023.
- [3] Đặng Hùng Thắng. *Lý thuyết Xác suất và Thống kê Toán học*. Tái bản mới nhất. Hà Nội, Việt Nam: Nhà xuất bản Giáo dục Việt Nam, 2020.
- [4] Macquarie University. *ACST3060/ACST8085: Quantitative Methods for Risk Analysis – Exercise Booklet*. Session 2, 2024. Updated Friday 2nd August, 2024. Aug. 2024.
- [5] Alexander J. McNeil, Rüdiger Frey, and Paul Embrechts. *Quantitative Risk Management: Concepts, Techniques and Tools*. Revised. Princeton Series in Finance. Princeton and Oxford: Princeton University Press, 2015. ISBN: 978-0-691-16627-8.

Phụ lục A

A.1 Data Preprocessing and Descriptive Statistics

The following code sets up library configuration, processes closing price data series, and performs univariate descriptive statistics and normal distribution testing (Jarque-Bera).

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from scipy.optimize import minimize
6 from scipy.stats import norm, skew, kurtosis, jarque_bera, t, chi2,
   gamma
7
8 # PLOTTING CONFIGURATION
9 sns.set_theme(style="whitegrid")
10 plt.rcParams['figure.figsize'] = [10, 6]
11
12 print("--- Processing input data ---")
13 df = pd.read_csv('all_stocks_5yr.csv')
14 df['date'] = pd.to_datetime(df['date'])
15
16 tickers = ['AAPL', 'MSFT', 'AMZN', 'GOOGL']
17 df_portfolio = df[df['Name'].isin(tickers)].copy()
18
19 df_pivot = df_portfolio.pivot(index='date', columns='Name', values='
   close').dropna()
20 returns = df_pivot.pct_change().dropna()
21
22 print("\n--- Descriptive Statistics and Jarque-Bera Test ---")
23 univariate_stats = pd.DataFrame(index=['Mean (%)', 'Std Dev (%)', '
   Skewness', 'Kurtosis', 'JB p-value'])
24
25 for t_ticker in tickers:
26     ret_series = returns[t_ticker].values
27     jb_stat, jb_p = jarque_bera(ret_series)
28     univariate_stats[t_ticker] = [
29         np.mean(ret_series) * 100,
30         np.std(ret_series) * 100,
31         skew(ret_series),
32         kurtosis(ret_series),
33         jb_p
34     ]
35 print(univariate_stats.round(4))
```

A.2 Dependency Model and Copula

This section computes the Spearman rank correlation matrix and empirical tail correlation coefficients to assess nonlinear dependence during crisis states.

```
1 print("\n--- Copula Dependency Structure ---")
2 spearman_corr = returns.corr(method='spearman')
3 print("Spearman Correlation Matrix:")
4 print(spearman_corr.round(4))
5
6 print("\nTail Dependency Coefficient (Crisis State):")
```

```

7 tail_dep = pd.DataFrame(1.0, index=tickers, columns=tickers)
8 for i in range(len(tickers)):
9     for j in range(i+1, len(tickers)):
10         t1, t2 = tickers[i], tickers[j]
11         u1 = returns[t1].rank(pct=True)
12         u2 = returns[t2].rank(pct=True)
13         joint_prob = np.mean((u1 <= 0.05) & (u2 <= 0.05))
14         lambda_l = joint_prob / 0.05
15         tail_dep.loc[t1, t2] = lambda_l
16         tail_dep.loc[t2, t1] = lambda_l
17 print(tail_dep.round(4))

```

A.3 Markowitz Portfolio Optimization

SLSQP algorithm is employed to solve the minimum variance portfolio (MVP) and maximum Sharpe ratio tangency portfolio problem, combined with efficient frontier visualization.

```

1 num_assets = len(tickers)
2 mean_returns_ann = returns.mean() * 252
3 cov_matrix_ann = returns.cov() * 252
4 risk_free_rate = 0.02
5
6 def portfolio_performance(weights, mean_returns, cov_matrix):
7     p_return = np.sum(mean_returns * weights)
8     p_std = np.sqrt(np.dot(weights.T, np.dot(cov_matrix, weights)))
9     return p_std, p_return
10
11 def minimize_variance(weights, mean_returns, cov_matrix):
12     return portfolio_performance(weights, mean_returns, cov_matrix)[0]
13
14 def negative_sharpe_ratio(weights, mean_returns, cov_matrix, rf):
15     p_std, p_return = portfolio_performance(weights, mean_returns,
16     cov_matrix)
17     return -(p_return - rf) / p_std
18
19 constraints = ({'type': 'eq', 'fun': lambda x: np.sum(x) - 1})
20 bounds = tuple((0, 1) for asset in range(num_assets))
21 initial_guess = num_assets * [1. / num_assets,]
22
23 # FIND MVP POINT
24 mvp_result = minimize(minimize_variance, initial_guess,
25     args=(mean_returns_ann, cov_matrix_ann),
26     method='SLSQP', bounds=bounds, constraints=
27     constraints)
28 mvp_std, mvp_return = portfolio_performance(mvp_result.x,
29     mean_returns_ann, cov_matrix_ann)
30
31 # FIND MAX SHARPE POINT
32 sharpe_result = minimize(negative_sharpe_ratio, initial_guess,
33     args=(mean_returns_ann, cov_matrix_ann,
34     risk_free_rate),
35     method='SLSQP', bounds=bounds, constraints=
36     constraints)
37 max_sharpe_std, max_sharpe_return = portfolio_performance(sharpe_result.
38     x, mean_returns_ann, cov_matrix_ann)
39

```

```

34 best_weights = sharpe_result.x
35 print(f"\n=> Optimal weights (Max Sharpe): {np.round(best_weights*100,
    2)}")
36
37 # PLOT EFFICIENT FRONTIER & CML
38 num_portfolios = 5000
39 port_results = np.zeros((3, num_portfolios))
40 np.random.seed(42)
41
42 for i in range(num_portfolios):
43     w = np.random.random(num_assets)
44     w /= np.sum(w)
45     p_std, p_return = portfolio_performance(w, mean_returns_ann,
    cov_matrix_ann)
46     port_results[0, i] = p_std
47     port_results[1, i] = p_return
48     port_results[2, i] = (p_return - risk_free_rate) / p_std
49
50 plt.scatter(port_results[0,:], port_results[1,:], c=port_results[2,:],
    cmap='viridis', marker='o', s=10, alpha=0.25)
51 plt.colorbar(label='Sharpe Ratio')
52 plt.scatter(0, risk_free_rate, color='black', marker='o', s=100)
53 plt.scatter(mvp_std, mvp_return, color='blue', marker='D', s=120)
54 plt.scatter(max_sharpe_std, max_sharpe_return, color='red', marker='*',
    s=250)
55
56 cml_x = np.linspace(0, max_sharpe_std * 1.4, 100)
57 cml_slope = (max_sharpe_return - risk_free_rate) / max_sharpe_std
58 cml_y = risk_free_rate + cml_slope * cml_x
59 plt.plot(cml_x, cml_y, color='purple', linestyle='--', linewidth=2)
60
61 plt.title("Markowitz Efficient Frontier with CML")
62 plt.xlabel("Systematic Risk")
63 plt.ylabel("Expected Annual Return")
64 plt.tight_layout()
65 plt.savefig('efficient_frontier_with_cml.png')
66 plt.show()

```

A.4 Copula Goodness-of-Fit and Cramer-von Mises Error

Process to estimate goodness-of-fit between empirical data and theoretical Copula models (Gaussian, t-Student, Clayton) to select the optimal model.

```

1 print("\n--- Copula Goodness-of-Fit and Cramer-von Mises Error ---")
2
3 pseudo_obs = returns.rank(pct=True)
4 U = pseudo_obs.values
5 clayton_theta = 2.0
6
7 spearman_corr = returns.corr(method='spearman')
8 np.random.seed(42)
9 sample_idx = np.random.choice(len(U), min(500, len(U)), replace=False)
10 U_sample = U[sample_idx]
11
12 def empirical_copula(u, data):
13     return np.mean(np.all(data <= u, axis=1))
14

```

```

15 def gen_copula_u(c_name, size):
16     mean_0 = np.zeros(num_assets)
17     sp_mat = spearman_corr.values
18     if c_name == 'Gaussian':
19         return norm.cdf(np.random.multivariate_normal(mean_0, sp_mat,
20 size))
21     elif c_name == 't-Student (df=4)':
22         w = chi2.rvs(4, size=size)
23         z = np.random.multivariate_normal(mean_0, sp_mat, size) * np.
24 sqrt(4 / w)[:, None]
25         return t.cdf(z, df=4)
26     else:
27         v = gamma.rvs(a=1/clayton_theta, scale=1, size=size)
28         e = np.random.exponential(scale=1, size=(size, num_assets))
29         return (1 + e / v[:, None]) ** (-clayton_theta)
30
31 gof_scores = {'Gaussian': 0, 't-Student (df=4)': 0, 'Clayton': 0}
32 sim_size_gof = 10000
33
34 u_sim_dict = {name: gen_copula_u(name, sim_size_gof) for name in
35 gof_scores.keys()}
36
37 for u_pt in U_sample:
38     emp_val = empirical_copula(u_pt, U)
39     for name in gof_scores.keys():
40         gof_scores[name] += (emp_val - empirical_copula(u_pt, u_sim_dict
41 [name]))**2
42
43 print("MSE Error Scores:")
44 for name, score in gof_scores.items():
45     print(f" - {name}: {score:.4f}")
46
47 best_copula = min(gof_scores, key=gof_scores.get)
48 print(f"> Best Model: {best_copula.upper()}")

```

A.5 Monte Carlo Simulation with Empirical Copula

Code generates 10,000 random return scenarios, then analyzes Value at Risk (VaR) and Conditional Value at Risk (CVaR).

```

1 print("\n--- Monte Carlo Simulation with Empirical Copula ---")
2 spearman_corr = returns.corr(method='spearman')
3
4 num_simulations = 10000
5 mean_vector = np.zeros(num_assets)
6 sim_normal = np.random.multivariate_normal(mean_vector, spearman_corr.
7 values, size=num_simulations)
8
9 u_sim = norm.cdf(sim_normal)
10
11 sim_returns = np.zeros((num_simulations, num_assets))
12 for i, ticker in enumerate(tickers):
13     sim_returns[:, i] = np.quantile(returns[ticker].values, u_sim[:, i])
14
15 # FIGURE 2: INITIAL EQUAL-WEIGHT PORTFOLIO
16 equal_weights = np.array([0.25, 0.25, 0.25, 0.25])
17 portfolio_sim_returns_eq = np.dot(sim_returns, equal_weights)

```

```

17
18 var_95_eq = np.quantile(portfolio_sim_returns_eq, 0.05)
19
20 plt.figure()
21 sns.histplot(portfolio_sim_returns_eq, bins=50, kde=True, color='skyblue',
22             ', stat='density')
23 plt.axvline(var_95_eq, color='red', linestyle='--', linewidth=2)
24 plt.title("Portfolio Return Distribution from Copula Simulation")
25 plt.tight_layout()
26 plt.savefig('copula_monte_carlo_daily_var.png')
27
28 # FIGURE 3: OPTIMAL CVaR PORTFOLIO
29 portfolio_sim_returns_opt = np.dot(sim_returns, best_weights)
30
31 var_95_opt = np.quantile(portfolio_sim_returns_opt, 0.05)
32 cvar_95_opt = portfolio_sim_returns_opt[portfolio_sim_returns_opt <=
33     var_95_opt].mean()
34
35 plt.figure()
36 sns.histplot(portfolio_sim_returns_opt, bins=50, kde=True, color='purple',
37             ', stat='density')
38 plt.axvline(var_95_opt, color='red', linestyle='--', linewidth=2)
39 plt.axvline(cvar_95_opt, color='orange', linestyle='--', linewidth=2)
40 plt.title("Optimal Portfolio Return Distribution - Tail Risk Control")
41 plt.tight_layout()
42 plt.savefig('optimal_cvar_portfolio.png')
43 plt.show()

```

A.6 Monte Carlo Simulation Long-Term Forecast (1 Year)

Process to generate asset price paths over 252 trading days to estimate returns and net risk at year-end.

```

1 print("\n--- Monte Carlo Simulation Deployment (1 Year / 252 Days) ---")
2 num_simulations = 10000
3 num_days = 252
4
5 mean_vector = np.zeros(num_assets)
6 portfolio_paths = np.ones((num_days + 1, num_simulations))
7
8 np.random.seed(42)
9 for day in range(num_days):
10     sim_normal = np.random.multivariate_normal(mean_vector,
11         spearman_corr.values, size=num_simulations)
12     u_sim = norm.cdf(sim_normal)
13
14     day_returns = np.zeros((num_simulations, num_assets))
15     for i, ticker in enumerate(tickers):
16         day_returns[:, i] = np.quantile(returns[ticker].values, u_sim[:,
17             i])
18
19     portfolio_sim_returns = np.dot(day_returns, best_weights)
20     portfolio_paths[day + 1, :] = portfolio_paths[day, :] * (1 +
21         portfolio_sim_returns)
22
23 # Asset Path Random Walk Plot

```

```

21 plt.figure()
22 plt.plot(portfolio_paths[:, :100], color='blue', alpha=0.08)
23 plt.axhline(1.0, color='red', linestyle='--', linewidth=1.5)
24 plt.title("Monte Carlo Simulation Asset Path Scenarios (1 Year)")
25 plt.tight_layout()
26 plt.savefig('monte_carlo_paths.png')
27 plt.show()
28
29 # Year-End Asset Value Distribution Plot
30 final_assets = portfolio_paths[-1, :]
31 var_95_yearly = np.quantile(final_assets, 0.05)
32
33 plt.figure()
34 sns.histplot(final_assets.flatten(), bins=50, kde=True, color='seagreen',
35              , stat='density')
36 plt.axvline(var_95_yearly, color='red', linestyle='--', linewidth=2)
37 plt.title("Distribution of Cumulative Portfolio Asset Value at Year-End")
38 plt.tight_layout()
39 plt.savefig('final_asset_distribution.png')
40 plt.show()

```